

Statistique descriptive

Série statistique à deux variables

On donne ci-dessous le nombre d'étudiants diplômés d'un Master en mathématiques et statistiques aux États-Unis¹ ainsi que le nombre de programmeurs informatiques en Californie² entre 2012 et 2021.

¹ étude du Centre National pour les Statistiques sur l'Éducation (NCES) des États-Unis.

² étude du Bureau des Statiques sur l'Emploi (BLS) des États-Unis.

Année	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021
Diplômés	6246	6957	7273	7589	8451	9082	10443	11382	12041	12583
Programmeurs	41540	38750	37990	38650	37570	34050	29740	24400	21800	23960

On souhaite évaluer si il existe un lien (une corrélation) entre ces données.

Définition :

On considère deux caractéristiques x et y d'une même population.


On définit une **série statistique à deux variables** x et y prenant les valeurs $x_1, \dots, x_i, \dots, x_n$ et $y_1, \dots, y_i, \dots, y_n$ par un tableau comme celui-ci :

Première variable x	x_1	$\dots$	x_i	$\dots$	x_n
Deuxième variable y	y_1	$\dots$	y_i	$\dots$	y_n

1 Nuage de points

Définition :

On parle d'un nuage de point représentant une série statistique à deux variables lorsqu'on place, dans un repère orthogonal, l'ensemble des points de coordonnées $(x_i ; y_i)$, c'est-à-dire tous les points $(x_n ; y_n)$, $(x_n ; y_n)$ jusqu'à $(x_n ; y_n)$.



Sur Géogebra :

Affichage > Tableur, remplir les données,
puis Statistiques à deux variables > Analyse

Définition : Point moyen


On note $\bar{x}$ et $\bar{y}$ les moyennes respectives de la série x et de la série y .

Le point moyen de la série statistique à deux variables est alors le point de coordonnées $(\bar{x} ; \bar{y})$.

Exemple :

$$\bar{x} = \frac{6246 + 6957 + 7273 + 7589 + 8451 + 9082 + 10443 + 11382 + 12041 + 12583}{10}$$

$$\bar{y} = \frac{41540 + 38750 + 37990 + 38650 + 37570 + 34050 + 29740 + 24400 + 21800 + 23960}{10}$$





2 Ajustement affine

2.1 Droite de regression

Lorsque les points d'un nuage sont sensiblement alignés, on peut construire une droite, appelé droite d'ajustement, ou **droite de régression**, passant « au plus près » de ces points.

On pourra toujours choisir plusieurs droite, l'objectif sera alors de minimiser les écarts avec les points. Plusieurs techniques sont possibles.



2.2 Interpolation / Extrapolation

Pour un nuage de points donné, on peut (à l'aide d'un ajustement affine par exemple) déterminer des valeurs « manquantes », qui seraient à l'intérieur des données étudiées : on parle d'**interpolation**.


On peut aussi « prolonger » le nuage en envisageant des valeurs qui seraient en dehors des données étudiées : on parle alors d'**extrapolation**.

2.3 Methode de Mayer

On souhaite approcher un nuage de points par une droite, ce qui nécessite deux points.

La droite de Mayer est une approximation du nuage de points qui passe par deux points moyens :

- On coupe la série statistique en deux sous séries d'effectifs similaires.
- On calcule les coordonnées du point moyen PM_1 de la première sous-série obtenue.
- On calcule les coordonnées du point moyen PM_2 de la deuxième sous-série obtenue.
- La droite de Mayer est la droite $(PM_1 PM_2)$




2.4 Méthode des moindres carrés

Définition : variance

La variance d'une série statistique x , notée $var(x)$ est la moyenne des écarts à la moyenne au carré :

$$var(x) = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_i - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Lorsqu'on trace une régression linéaire avec la méthode des moindres carrés, on cherche à minimiser la somme des carrés des distances entre les points et la droite qu'on va tracer ; le plus souvent pour y , mais on peut aussi le faire pour x .



La droite de régression par la méthode des moindres carrés passe par le point moyen de la série statistique à deux variables.

Définition : covariance

On appelle covariance de la série statistique à deux variables, notée $cov(x, y)$, le nombre :

$$\frac{(x_1 - \bar{x})(y_1 - \bar{y}) + \dots + (x_i - \bar{x})(y_i - \bar{y}) + \dots + (x_n - \bar{x})(y_n - \bar{y})}{n} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Remarque : En remplaçant y par x dans la formule de la covariance, on voit bien l'analogie entre la variance d'une variable x et la covariance de deux variables x et y .

Propriété :

$$cov(x, y) = \frac{(x_1 \times y_1) + \dots + (x_i \times y_i) + \dots + (x_n \times y_n)}{n} - \bar{x} \times \bar{y} = \frac{1}{n} \sum_{i=1}^n x_i \times y_i - \bar{x} \times \bar{y}$$

Soit une série statistique à deux variables x et y de covariance $cov(x, y)$ et dont la variable x a pour moyenne $\bar{x}$ et pour variance $var(x)$, et dont la variable y a pour moyenne $\bar{y}$ et pour variance $var(y)$:

- La droite de régression de y en x possède une équation réduite de la forme $y = ax + b$ où :

→ le coefficient directeur $a = \frac{cov(x, y)}{var(x)}$

→ b vérifie l'équation $\bar{y} = a\bar{x} + b$ (puisque cette droite de régression passe par le point moyen), soit $b = \bar{y} - a\bar{x}$

- La droite de régression de x en y possède une équation réduite de la forme $x = a'y + b'$ où :

→ le coefficient directeur $a' = \frac{cov(x, y)}{var(y)}$

→ $b' = \bar{x} - a'\bar{y}$

3 Coefficient de corrélation

Définition : coefficient de corrélation

Le coefficient de corrélation linéaire d'une série statistique à deux variables x et y , noté r , est le nombre défini par $r = \frac{cov(x, y)}{\sqrt{var(x) \times var(y)}}$

Interprétation :

Le coefficient de corrélation r est un nombre compris entre -1 et 1 qui mesure la relation entre les deux variables x et y .

Plus le coefficient est proche des valeurs extrêmes -1 et 1 , plus la corrélation linéaire entre les variables est forte.

→ Si $r > 0$, les valeurs prises par y ont tendance à croître quand les valeurs de x augmentent,

→ si $r < 0$, les valeurs prises par y ont tendance à décroître quand les valeurs de x augmentent,

→ si $r = 0$, les variations des variables x et y sont indépendantes.

Exemples de nuages de points en fonction du coefficient de corrélation :



Correlation vs lien de cause à effet : *cum hoc sed non propter hoc*

ATTENTION, des données fortement corrélées ne signifie que les données ont un lien de cause à effet. Certaines corrélation peuvent résulter du hasard et n'avoir aucun lien.

Il peut d'ailleurs être amusant de volontairement choisir des données totalement indépendantes mais qui ont une corrélation forte pour inventer des liens :

le nombre de nids de cigognes et celui des naissances humaines par exemple !