

Chapitre 11: Échantillonnage.


Introduction:

Pourquoi travailler avec des échantillons ? Deux choses :

- L'étude détruit l'individu (ex : on s'intéresse à la durée de vie d'une ampoule, mieux vaut tester une petite quantité, un échantillon, que la totalité produite)
- La population est trop grande pour que l'étude soit réalisable.

Dans ce cas là, on parlera de statistique inférentielles. C'est à dire qu'on s'intéresse à la détermination des paramètres d'une population complète à partir de ceux d'un échantillon.

Dans la cas inverse, l'échantillonnage statistique consiste à prédire, à partir d'une population connue, les caractéristiques des échantillons qui en seront prélevés.



Problématique : On lance 100 fois une pièce de monnaie. Le côté pile est apparu 61 fois. Peut on dire que la pièce est truquée ?

I- Fluctuation d'échantillonnage.

Définition : On appelle **échantillon** de taille n , la liste des résultats obtenus par n répétitions d'une même expérience aléatoire.

On s'intéresse au nombre de fois où le caractère prend une certaine valeur prédéfinie à l'avance.

Exemple : Dans notre exemple, on s'intéresse à la fréquence d'apparition de la face pile sur 100 échantillons de taille 100.

On remarque que la fréquence varie d'un échantillon à un autre. C'est ce qu'on appelle la fluctuation d'échantillonnage.

Définition : Lorsque l'on répète plusieurs fois la même expérience, la distribution des fréquences observées de l'événement « le caractère prend la valeur choisie » varie. On parle alors de **fluctuation d'échantillonnage**.

D'après la loi faible des grands nombres, la fréquence observée tend vers la probabilité théorique de l'événement considéré.

Maintenant, on s'intéresse à la manière dont ces fluctuations sont établies.

II- Intervalle de fluctuation d'une proportion ou fréquence.

Définition : Un intervalle de fluctuation I des fréquences observées au seuil de 95 % est tout intervalle :


- contenant p , la fréquence théorique de ce que l'on observe.
- $P(f_n \in I) \geq 0,95$ où f_n est la fréquence observée au n -ième échantillon.

On peut également choisir un seuil de 90 % ou 99 %. Cela dépend de l'importance de la situation que l'on étudie.

Comment déterminer cet intervalle ?

x Avec la loi binomiale.

- On suppose que la proportion d'un caractère dans une population est connue, égale à p . On prélève au hasard dans cette population des échantillons de taille n , et on s'intéresse à la variable aléatoire X qui, à chaque échantillon, associe le nombre de réalisations du caractère : il y a répétition d'une épreuve de Bernoulli de manière indépendante, donc X suit la loi binomiale de paramètres n et p .
- On veut obtenir un intervalle $B = [a ; b]$ tel que $P(X \in B) \geq 95 \%$.
On partage l'ensemble des valeurs prises par X en trois intervalles A , B et C disjoints, de réunion $\{0, 1, 2, \dots, n\}$. On cherche les intervalles A et C les « plus grands possibles » tels que $P(X \in A) \leq 2,5 \%$ et $P(X \in C) \leq 2,5 \%$. On aura bien alors un intervalle B « minimal » tel que la probabilité que X appartienne à $B = [a ; b]$ soit au moins égale à 0,95.
- On définit A , B et C de la façon suivante : A : valeurs comprises entre 0 et $a - 1$ (a entier) ; B : valeurs comprises entre a et b (b entier) ; C : valeurs comprises entre $b + 1$ et n .



Le réel a vérifie ainsi : $P(X < a) \leq 0,025$ et $P(X \leq a) > 0,025$.

Le réel b vérifie ainsi : $P(X > b) \leq 0,025$ et $P(X \geq b) < 0,025$.

La condition $P(X > b) \leq 0,025$ équivaut à $1 - P(X \leq b) \leq 0,025$, soit $P(X \leq b) \geq 0,975$.

La taille de l'échantillon étant n , la fréquence de réalisations de X est $\frac{1}{n} X$, donc la probabilité que la fréquence soit dans $\left[\frac{a}{n}, \frac{b}{n}\right]$ est au moins égale à 0,95.

Propriété : L'intervalle de fluctuation au seuil 95 % d'une proportion, observée, sur un échantillon de taille n , d'une variable aléatoire X suivant une loi binomiale de paramètre n et p est l'intervalle $\left[\frac{a}{n}, \frac{b}{n}\right]$ tel que :

- a est le plus petit entier tel que $P(X \leq a) > 0,025$ et
- b est le plus petit entier tel que $P(X \leq b) \geq 0,975$

Exemple. Un joueur de tennis confirmé sert une première balle bonne 6 fois sur 10. Déterminer, en utilisant la loi binomiale, l'intervalle de fluctuation de la proportion des premières balles bonnes sur une série de 25 engagements.

On note X la variable aléatoire prenant pour valeur le nombre de premières balles bonnes sur 25 engagements.

X suit la loi binomiale de paramètres $n = 25$ et $p = 0,6$.

L'intervalle de fluctuation de la proportion de premières balles bonnes sur 25 engagements au seuil de 95 % est :

$$I = \left[\frac{a}{n} ; \frac{b}{n} \right],$$

où a est le plus petit entier tel que $P(X \leq a) > 0,025$;

et b est le plus petit entier tel que $P(X \leq b) \geq 0,975$.

Pour déterminer a et b , on utilise la table des probabilités cumulées croissantes $P(X \leq k)$ de la loi $\mathcal{B}(25 ; 0,6)$.

On obtient cette table de valeurs à l'aide d'une calculatrice.

Avec la calculatrice TI 82 stats.fr ou 83 Plus.fr

On tape $f(x)$, sur la ligne $Y1=$ on tape 2^{nd} var pour distrib.

On sélectionne $A:binomFRép($ entrer et on complète la ligne $(25, 0.6, X)$ entrer

Pour obtenir la table on tape 2^{nd} $graphe$.

On obtient l'écran suivant :

X	Y1
7	.00121
8	.00432
9	.01317
10	.03438
11	.0778
12	.15377
13	.26772

Avec la calculatrice Casio Graph 35+

On tape $MENU$, on sélectionne $STAT$ EXE .

Dans $List1$ on saisit les valeurs prises par X : 0, 1, 2, 3 ... 25.

On tape $F5$ pour $DIST$, $F5$ pour $BINM$, $F2$ pour Bcd , $F1$ pour $List$.

Sur la ligne $Numtrial$ on saisit 25 EXE .

Sur la ligne P on saisit 0.6 EXE .

On sélectionne $Execute$ EXE .

On obtient l'écran suivant :

Binomial C.D	
10	0.0131
11	0.0778
12	0.1537
13	0.2677
14	0.2677
0.03439151809	

Attention ! Sur la ligne 11 on lit $P(X \leq 10)$.

On peut aussi utiliser un tableur ou le logiciel Sine Qua Non.

x Avec la loi binomiale approchée par une loi normale.

Rappel : si $n \geq 50$ et $np(1-p) > 10$ on peut alors approcher une loi binomiale par une loi normale.

Propriété : La variable aléatoire F qui, à tout échantillon aléatoire prélevé avec remise et de taille n , associe la proportion du caractère considéré dans l'échantillon suit approximativement la loi normale $N(p; \frac{p(1-p)}{n})$

Propriété : L'intervalle de fluctuation de f au seuil $1-\alpha$ est donné par :


$I = [p - u_\alpha \sqrt{\frac{p(1-p)}{n}} ; p + u_\alpha \sqrt{\frac{p(1-p)}{n}}]$, avec u_α l'unique réel tel que $P(-u_\alpha \leq Z \leq u_\alpha) = 1-\alpha$ où Z suit une loi normale $N(0;1)$.

Valeurs à connaître :

- Si $\alpha=0,01 \Rightarrow 1-\alpha=0,99 \Rightarrow u_\alpha=2,58$
- Si $\alpha=0,05 \Rightarrow 1-\alpha=0,95 \Rightarrow u_\alpha=1,96$
- Si $\alpha=0,1 \Rightarrow 1-\alpha=0,9 \Rightarrow u_\alpha=1,645$.

Règle de décision

- La détermination d'un intervalle de fluctuation permet de prendre une décision lorsqu'on fait une hypothèse sur une proportion ou une probabilité dans une population.
- En effet, en faisant une hypothèse sur la proportion p d'un caractère dans une population, on peut déterminer un intervalle de fluctuation I à 95 % de la fréquence de ce caractère dans un échantillon aléatoire de taille n : la fréquence observée dans un échantillon prélevé dans la population appartient à I dans au moins 95 % des cas.
- Ainsi, on établira une **règle de décision** : si la fréquence observée dans l'échantillon n'appartient pas à I , comme cela n'arrive que dans au plus 5 % de ces échantillons, on rejettera l'hypothèse faite sur p , avec un risque de se tromper de 5 %.



On en déduit la propriété suivante :

Propriété On considère une population dans laquelle on suppose que la proportion d'un caractère est p . Après expérience, on observe la fréquence f de ce caractère dans un échantillon aléatoire de taille n .
Soit l'hypothèse : « La proportion de ce caractère dans la population est p . »
Soit I l'intervalle de fluctuation de la fréquence à 95 % dans les échantillons de taille n .
Si $f \notin I$: on rejette cette hypothèse au seuil de risque 5 %.
Sinon, on ne rejette pas cette hypothèse au seuil de risque 5 % ; on l'accepte.

Retour à la problématique : Le pièce est elle alors truquée ?


Ex : 2, 4 p92 ; 6, 7, 8, 10, 11 p93

III- Intervalle de fluctuation d'une moyenne.

On dispose d'une population sur laquelle est définie une variable aléatoire X dont on connaît l'espérance (ou la moyenne) μ et l'écart type σ .

On s'intéresse aux échantillons de taille n . Auront-ils tous la même moyenne ?

Non, certains peuvent être constitués d'éléments atypiques et avoir une moyenne très différente de celle de la population (surtout si l'échantillon est de petite taille).



Pour prélever les échantillons de taille n , on a procédé à n épreuves indépendantes de variables aléatoires $X_1, X_2, \dots, X_n$ de même loi que X .

La variable aléatoire $\bar{X}_n = \frac{X_1 + X_2 + \dots + X_n}{n}$ associe à tout échantillon de taille n sa moyenne.

Théorème de la limite centrée :

Contexte : La variable aléatoire X suit une loi quelconque sur la population avec $E(X) = \mu$ et $\sigma(X) = \sigma$.

On prélève, au hasard, un échantillon de taille n , avec $n > 30$, de moyenne .

Alors la variable aléatoire $\bar{X}_n$ suit approximativement la loi normale $N(\mu ; \frac{\sigma^2}{n})$

Exemple 1 : Une machine fabrique des pièces en grande série. A chaque pièce tirée au hasard, on associe sa longueur exprimée en millimètres ; on définit ainsi une variable aléatoire X .

On suppose que X suit la loi normale $N(28,20 ; 0,027)$

Soit M_n la variable aléatoire qui à tout échantillon de taille n associe la moyenne des longueurs des n pièces de l'échantillon.

Le résultat précédent nous dit que pour n assez grand :

M_n suit la loi normale $N(\dots\dots\dots ; \dots\dots\dots)$

Supposons que les échantillons soient de taille 100, alors, M_{100} suit la loi normale $N(\dots\dots\dots ; \dots\dots\dots)$

Exemple 2 : Les statistiques des notes obtenues en mathématiques au bac STI en France pour l'année 2006 sont : Moyenne nationale : $\mu = 10,44$

Ecart type : $\sigma = 1,46$

Une classe de BTS comporte 35 élèves en 2006/2007 issus d'un bac STI en 2006.

Calculer la probabilité que la moyenne de cette classe soit supérieure à 10.

.....

Propriété : L'intervalle de fluctuation de m_e au seuil $1 - \alpha$ est donné par :

$I = [m - u_\alpha \frac{\sigma}{\sqrt{n}} ; m + u_\alpha \frac{\sigma}{\sqrt{n}}]$, avec u_α l'unique réel tel que $P(-u_\alpha \leq Z \leq u_\alpha) = 1 - \alpha$ où Z suit une loi normale $N(0;1)$.

Ex : 12, 14, 15 p94