

Statistiques à deux variables

1) Introduction

☞ « Depuis 1975, la température moyenne sur le globe augmente dangereusement. Pour de nombreux scientifiques, ce phénomène est directement lié à l'augmentation des émissions de CO₂ due à l'activité humaine. Ils prédisent pour les vingt ans à venir, un réchauffement moyen de 0,2 °C par décennie. »

Comment les scientifiques ont pu faire cette prévision ?

Tout d'abord, il faut des données depuis un certain nombre d'années concernant : les émissions de CO₂ et la température moyenne sur Terre. On a donc **2 variables**, et on essaie de voir le lien qu'elles ont entre elles. On est ainsi dans **les statistiques à deux variables**, et le lien s'appelle **un ajustement**. Par ailleurs, une fois qu'on a trouvé le lien entre les deux variables qui fonctionne, on peut prédire ce qui se passera plus tard.

☞ On illustrera les notions abordées dans ce cours avec l'exemple suivant :

Exemple : Le tableau suivant donne l'évolution du nombre d'adhérents d'un club de rugby de 2001 à 2006.


Année	2001	2002	2003	2004	2005	2006
Rang de l'année x_i	1	2	3	4	5	6
Nombre d'adhérents y_i	70	90	115	140	170	220

Le but est d'étudier cette série statistique à deux variables (le rang de l'année et le nombre d'adhérents) afin de prévoir l'évolution du nombre d'adhérents pour les années suivantes.

2) Nuage de points – Point moyen

Définition : Dans un repère orthogonal, l'ensemble des points de coordonnées $(x_i ; y_i)$ est appelé le **nuage de points** associé à cette série statistique à deux variables.

Question 1 : Sur le graphique ci-dessous, représenter le nuage de points associé à la série.



Définition : Le point G de coordonnées $(\bar{x} ; \bar{y})$ est appelé le **point moyen** du nuage de points associé à cette série statistique à deux variables.

Question 2 : Calculer les coordonnées du point moyen G et le placer sur le graphique (utiliser une couleur différente)

$\bar{x} = \dots\dots\dots$ $\bar{y} = \dots\dots\dots$

Utilisation de la calculatrice : voir fiche méthode 26 pages 183 à 185.

3) Ajustement affine par la méthode des moindres carrés


La recherche d'une dépendance entre les deux caractères x et y d'une série double conduit à l'analyse du nuage de points. Suivant la forme du nuage, on cherche une fonction f telle que sa courbe d'équation $y = f(x)$ passe « le plus près possible » des points du nuage.

Lorsque les points du nuage paraissent presque alignés (autrement dit le nuage a une forme allongée), on peut chercher une relation de la forme $y = ax + b$ qui exprime de façon approchée y en fonction de x , en s'ajustant au mieux avec les données. Graphiquement, cela signifie qu'on cherche **une droite qui passe au plus près de tous les points du nuage.**

Une droite d'ajustement passe toujours par le point moyen G du nuage.

Pour mesurer la qualité d'une telle formule, on considère, pour chaque valeur x_i , la différence entre la valeur observée, c'est à dire y_i , et la valeur calculée par la formule, c'est à dire $ax_i + b$. On souhaite que toutes les différences : $y_i - (ax_i + b)$ appelées **erreurs**, ou **résidus**, ou **perturbations**, soient les plus petites possibles.

La méthode la plus couramment employée, dite **méthode des moindres carrés**, consiste à choisir a et b de façon que la **somme des carrés des résidus soit la plus petite possible**.



Théorème et définition : Etant donné un nuage de n points $A_i (x_i ; y_i)$, il existe une unique droite passant par le point moyen G du nuage telle que la somme des carrés des écarts $(A_i P_i)^2$ soit minimale. Cette droite s'appelle la **droite de régression de y en x**. Cette droite de régression a une équation $y = ax + b$ où les valeurs de a et b sont obtenus à l'aide d'une calculatrice ou d'un logiciel.

Question 3 : Déterminer une équation de la droite d'ajustement d de y en x obtenue par la méthode des moindres carrés et la tracer sur le graphique précédent.

.....

Utilisation de la calculatrice : voir la fiche méthode 27 pages 186 à 188.

4) Coefficient de corrélation linéaire

Pour les nuages de points « allongés » qui incitent à ajuster par une droite nous allons introduire un nouveau paramètre afin d'apprécier la qualité d'un ajustement affine : le **coefficient de corrélation linéaire**, noté r . Il est obtenu à l'aide de la calculatrice ou d'un logiciel.

Propriété : Le coefficient de corrélation linéaire r vérifie : $-1 \leq r \leq 1$.

Interprétation : Plus le coefficient linéaire est proche de 1 (en valeur absolue), meilleur est l'ajustement linéaire.

Question 4 : Déterminer le coefficient de corrélation linéaire dans le cas de l'ajustement affine (entre x et y)

.....