

Statistique descriptive

Objectifs du chapitre

- Savoir synthétiser l'information issue de données réelles.
- Proposer des résumés numériques ou graphiques pertinents de ces données.
- Maîtriser l'utilisation de logiciels, notamment d'un tableur et de calculatrices dans ce but.

Pour reprendre contact

Dans chaque cas, indiquer la bonne réponse.

Une entreprise effectue des travaux d'isolation chez des particuliers. Elle souhaite évaluer son potentiel d'activité dans une ville. Pour cela, elle demande à 100 personnes choisies au hasard de faire le test suivant : une pièce, préalablement portée à une température convenue, est laissée toute une nuit sans chauffage. Le matin, on relève sa température. L'entreprise obtient comme résultats, arrondis au degré le plus proche :

Température (°C)	13	14	15	16	17	18	19	20
Effectifs	1	4	12	21	25	22	10	5

	Questions	Réponse A	Réponse B	Réponse C
1	La moyenne de cette série est à 10^{-2} près :	16,96	15,96	19,66
2	L'écart type est à 10^{-4} près :	1,0594	1,5094	1,9054
3	La médiane est :	16	17	18
4	Le premier quartile est :	16	17	18
5	L'écart interquartile est :	2	1	3

Activité 1



TICE

Pour faire connaissance

Une usine fabrique des plaques d'isolation phonique. Une machine de cette usine est chargée de percer des trous de 80 mm de diamètre dans des plaques.

Sur un échantillon de 100 diamètres de trous choisis dans plusieurs plaques, les valeurs ci-dessous ont été observées.

79,56	79,82	79,87	79,93	79,96	79,99	80,04	80,06	80,1	80,16
79,71	79,82	79,87	79,93	79,96	80	80,04	80,06	80,1	80,17
79,73	79,84	79,88	79,93	79,96	80	80,04	80,07	80,11	80,17
79,76	79,84	79,88	79,94	79,97	80,01	80,04	80,07	80,12	80,18
79,77	79,84	79,89	79,94	79,97	80,01	80,05	80,08	80,12	80,19
79,78	79,85	79,91	79,94	79,97	80,02	80,05	80,08	80,13	80,21
79,78	79,85	79,92	79,94	79,98	80,02	80,05	80,08	80,13	80,23
79,78	79,86	79,92	79,95	79,98	80,02	80,06	80,09	80,13	80,26
79,79	79,86	79,92	79,95	79,99	80,03	80,06	80,09	80,15	80,3
79,81	79,87	79,92	79,95	79,99	80,03	80,06	80,09	80,15	80,31

1 On regroupe les données en 10 classes d'amplitude 0,08.

a. Remplir le tableau des effectifs ci-dessous.

Classe	Effectif	Classe	Effectif
[79,54 ; 79,62[		[79,94 ; 80,02[	
[79,62 ; 79,7[		[80,02 ; 80,1[	
[79,7 ; 79,78[		[80,1 ; 80,18[	
[79,78 ; 79,86[		[80,18 ; 80,26[	
[79,86 ; 79,94[		[80,26 ; 80,34[	



b. Construire l'histogramme associé à ce tableau.

c. À partir du tableau des effectifs, calculer à l'aide de la calculatrice la moyenne et l'écart type de cet échantillon ainsi regroupé. On arrondira les résultats au centième.

d. Calculer le pourcentage de trous de cet échantillon dont le diamètre est compris entre 79,86 mm et 80,18 mm.


2 Dans la suite, on cherche à faire varier le nombre de regroupements par classes.

a. Avec le logiciel GeoGebra, on a obtenu deux histogrammes à partir de l'échantillon des 100 diamètres :



Comparer ces deux histogrammes entre eux et avec celui obtenu précédemment. Lequel de ces trois histogrammes permet de mieux dégager une tendance générale de la distribution des effectifs de la série statistique ?

b. On cherche maintenant à diminuer le nombre de regroupements par classes. Pour cela, ouvrir le logiciel GeoGebra. Sélectionner **Affichage** puis **Tableur**. Recopier le tableau du début de l'activité à partir de la cellule A1. Sélectionner les 100 cellules renseignées, puis cliquer sur l'icône **Statistiques à une variable**. Confirmer l'analyse des données. La fenêtre suivante s'ouvre :



L'icône permet de définir les classes « à la main ». Faire afficher les histogrammes correspondant à un nombre de classes de plus en plus petit à l'aide de cet onglet ou du curseur . Comparer les différents histogrammes obtenus et conclure sur la pertinence de ces regroupements par classes.

3 Sélectionner pour « afficher les statistiques ». Comparer les valeurs de la moyenne et de l'écart type obtenues par GeoGebra à partir de l'analyse de l'échantillon des 100 diamètres avec les valeurs obtenues dans la question 1.c à partir du regroupement des données en 10 classes.

Activité 2 Pour tester la sensibilité des indicateurs aux valeurs extrêmes

Une entreprise fabrique, en très grand nombre, des électrodes. Un technicien a reçu 10 électrodes de cette production. Il a mesuré les surfaces, en cm^2 , des électrodes de cet échantillon extrait de la production de l'entreprise et il a obtenu les résultats suivants : 4,8 ; 4,7 ; 5,1 ; 5,0 ; 4,9 ; 5,0 ; 5,2 ; 4,8 ; 5,0 ; 5,2.

1 Calculer la moyenne, l'écart type, la médiane et l'écart interquartile sur cet échantillon. On donnera le résultat à 10^{-4} près.


2 Dans son atelier, il restait au technicien deux électrodes de surfaces respectives 4,5 et 5,5.

a. Déterminer les paramètres statistiques de la série constituée par les surfaces des 12 électrodes.

b. Quelle est, à 1 % près, la variation en pourcentage de chacun des paramètres ?

c. Parmi les deux couples d'indicateurs (moyenne, écart type) et (médiane, écart interquartile), quel est le moins sensible aux valeurs extrêmes ?

3 Le technicien veut comparer la série constituée par les surfaces de ces 12 électrodes avec celle définie par le diagramme en bâtons ci-contre, où l'on peut lire en abscisse les valeurs des surfaces et en ordonnée les effectifs correspondants.



Calculer la moyenne, l'écart type, la médiane et l'écart interquartile de cette nouvelle série. On donnera le résultat à 10^{-4} près.

Interpréter ces résultats numériques.

Activité 3 Série statistique à deux variables

Une marque a lancé un nouveau produit destiné aux entreprises. Elle a relevé à six dates précises le taux d'équipement des entreprises concernées pour ce nouveau produit.

On a présenté dans le tableau suivant ce taux noté en fonction du nombre de mois écoulés depuis le lancement. Ce taux est écrit en pourcentage.

Rang x	$x_1 = 1$	$x_2 = 3$	$x_3 = 5$	$x_4 = 8$	$x_5 = 10$	$x_6 = 12$
Taux y	$y_1 = 1,5$	$y_2 = 8$	$y_3 = 17,5$	$y_4 = 32$	$y_5 = 48$	$y_6 = 73$

1 Représenter le nuage des six points C_i de coordonnées $(x_i; y_i)$ pour i allant de 1 à 6 dans un repère orthogonal (unités : 1 cm sur l'axe des abscisses et 0,1 cm sur l'axe des ordonnées).

2 Déterminer les coordonnées du point moyen G qui a pour abscisse la valeur moyenne des valeurs prises par x et pour ordonnée la valeur moyenne des valeurs prises par y . Placer G .

3 Le nuage de points a une forme allongée. On veut tracer plusieurs droites autour desquelles les points du nuage sont situés. On dit alors que chacune de ces droites réalise un ajustement affine de cette série statistique à deux variables.

a. Premier ajustement affine : déterminer les coordonnées du point moyen G' des trois premiers points du nuage et du point moyen G'' des trois derniers. Vérifier que l'équation réduite de la droite $(G'G'')$ est $y = 6x - 9$. Tracer $(G'G'')$. Vérifier que G est un point de $(G'G'')$.

b. Deuxième ajustement affine : déterminer l'équation réduite de la droite passant par G et de coefficient directeur 6,3 et la tracer.

c. Troisième ajustement affine : calculer l'accroissement moyen mensuel du taux entre 1 mois et 12 mois. En déduire que l'équation réduite de la droite (C_1C_6) est $y = 6,5x - 5$. Tracer (C_1C_6) . Le point G appartient-il à cette droite ?

4 On s'intéresse dans cette question à un quatrième ajustement affine qui est appelé « droite de régression de y en x » par la méthode des moindres carrés. On note d cette droite. C'est la droite d'ajustement qui passe par G et qui est telle que la somme des d_i^2 , pour i allant de 1 à 6, est minimale, où d_i est la distance entre le point du nuage d'abscisse x_i et le point de la droite d'ajustement ayant même abscisse. On va obtenir l'équation de cette droite d avec le logiciel GeoGebra.

Activités


a. Ouvrir *GeoGebra*. Dans le menu **Affichage**, sélectionner **Tableur**. Dans la colonne A, recopier les six valeurs prises par x . Dans la colonne B, recopier les six valeurs prises par y .

b. Taper $=A1,B1$ dans la cellule C1. Cela crée le point C1 de coordonnées (1 ; 1,5). Utiliser la poignée de copie pour copier cette formule vers le bas jusqu'à la cellule C6. On crée ainsi le nuage de points C1, C2, ..., C6.

c. Pour visualiser le nuage, on recadre la fenêtre d'affichage. Pour cela, faire un clic droit sur la zone **Graphique** et aller dans l'onglet **Graphique** puis dans l'onglet **Basique**. On choisit pour l'axe des abscisses, $xMin=-0.5$ et $xMax=15.5$ et pour l'axe des ordonnées, $yMin=-0.5$ et $yMax=100$.

d. Pour construire le point moyen du nuage avec les commandes de *GeoGebra*, taper $G=(moyenne[A1:A6], moyenne[B1:B6])$ dans la ligne de saisie et valider.

e. On veut créer un nombre a associé à un curseur. Pour cela, sélectionner l'outil **Curseur** . Cliquer ensuite dans la fenêtre **Graphique** et renseigner la fenêtre de dialogue qui s'ouvre de la manière suivante :



Puis cliquer sur **Appliquer**.

f. Créer la droite d passant par le point G de coefficient directeur a , en tapant dans la ligne de saisie :


$d:y=a*(x-x(G))+y(G)$. En modifiant le curseur associé à a , on modifie donc la direction de la droite d . Faire quelques essais.

g. On veut maintenant calculer et visualiser les distances d_i . Dans la cellule D1, taper $=Segment[C1,(A1-a*(A1-x(G))+y(G))]$. Recopier cette formule vers le bas jusqu'à la cellule D6. Les segments apparaissent sur le graphique.

h. On calcule la somme des carrés des longueurs des segments de la colonne D en tapant dans la cellule D7, $=SommeXX[D1:D6]$. Dans le cas où $a = 5,6$, on a obtenu le tableau ci-après.


	A	B	C	D	E
1	1	1.5	(1, 1.5)	2.3	
2	3	8	(3, 8)	2.4	
3	5	17.5	(5, 17.5)	4.1	
4	8	32	(8, 32)	6.4	
5	10	48	(10, 48)	1.6	
6	12	73	(12, 73)	12.2	
7				220.22	
8					

On fait apparaître ensuite cette somme dans la fenêtre **Graphique** : choisir l'outil **Insérer Texte**  et cliquer dans la fenêtre **Graphique**. Renseigner la fenêtre de dialogue qui s'ouvre de la manière suivante :



Puis cliquer sur **OK**.

i. Faire varier a (ci-dessous le cas $a = 5,6$) et choisir la valeur de a qui correspond à la plus faible valeur de la somme des carrés des écarts en lisant dans la zone de texte. Quelle est alors l'équation réduite de d ?



5 En utilisant la droite de régression de y en x par la méthode des moindres carrés que l'on vient d'obtenir, répondre à la question suivante : si la tendance se poursuit, quel sera, à 1 % près, le taux d'équipement des entreprises concernées pour ce nouveau produit 15 mois après le lancement ?

6 Expliquer pourquoi cette droite de régression ne pourra pas servir de modèle très longtemps.

1. Nuage moyen, point moyen d'une série statistique à deux variables


Soit S une série statistique à deux variables quantitatives discrètes X et Y de taille $n \in \mathbb{N}^*$ définie par $S = \{(x_i; y_i), 1 \leq i \leq n\}$.

- Dans un repère orthogonal, l'ensemble des points M_i de coordonnées $(x_i; y_i)$, où $1 \leq i \leq n$, est appelé **nuage de points associé à S** .
- Le **point moyen** du nuage est le point G de coordonnées $(\bar{X}; \bar{Y})$, où $\bar{X}$ et $\bar{Y}$ sont les moyennes arithmétiques de X et Y .

2. Ajustement affine par la méthode des moindres carrés

- Effectuer un **ajustement** de Y en X d'un nuage de points consiste à trouver une fonction f telle que la courbe d'équation $y = f(x)$ passe « au plus près » des points du nuage. Lorsque la fonction f est affine, on parle d'ajustement affine.

- On appelle **droite de régression de Y en X par la méthode des moindres carrés** l'unique droite qui minimise la somme des carrés des écarts (indiqués en rouge sur la figure ci-contre) entre le point du nuage d'abscisse x_i et le point de la droite ayant même abscisse.



Cette droite passe par le point moyen G . Elle a pour équation réduite $y = \text{cov}(X, Y) V(X)(x - \bar{X}) + \bar{Y}$, où $\text{cov}(X, Y)$ est la covariance de X et Y : c'est le nombre $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})(y_i - \bar{Y})$; $V(X)$ est la variance de X ;

enfin $\bar{X}$ et $\bar{Y}$ sont les moyennes arithmétiques respectives de X et de Y .

- Pour une valeur x donnée de la variable X , la droite de régression permet donc de prévoir la valeur correspondante y de la variable Y . Si x appartient à l'intervalle d'observation de la série X , c'est-à-dire si la valeur de x est comprise entre les valeurs extrêmes prises par X , on parle d'**interpolation**. Sinon, on parle d'**extrapolation**.

3. Coefficient de corrélation linéaire

La décision d'ajuster un nuage de points par une droite se prend :

- soit de manière qualitative en fonction de la forme de ce nuage (un nuage allongé),
- soit de manière quantitative à l'aide du coefficient de corrélation linéaire.

→ Définition

Le **coefficient de corrélation linéaire** est le nombre $r = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$, où $\text{cov}(X, Y)$ est la covariance de X et de Y et σ_X et σ_Y leur écart type. Ce nombre est compris entre -1 et 1 .


→ Propriétés

- $r = 1$ ou $r = -1$ est équivalent à l'existence d'une relation linéaire exacte.
- Plus r est proche des valeurs extrêmes -1 et 1 , plus la corrélation entre les variables est forte; on emploie alors l'expression « fortement corrélées » pour qualifier les deux variables. Une corrélation égale à 0 signifie que les variables ne sont pas corrélées.
- Le fait que deux variables soient « fortement corrélées » ne démontre pas qu'il y a une relation de cause à effet entre l'une et l'autre.

→ Exemples de coefficients de corrélation



$r = 0$



$r = -0,37$



$r = 0,82$



$r = -0,42$

Exercices résolus



A Utiliser un logiciel ou une calculatrice pour résumer et représenter une série statistique à une variable X

Une entreprise fabrique des pieds métalliques pour des lits. Dans la production d'une journée, on étudie un échantillon de 100 pieds dont on mesure les longueurs. On obtient la série suivante :

Longueur (en cm)	5,65	5,70	5,75	5,80	5,90	5,95
Effectif	8	28	27	9	21	7




Résumer numériquement cette série. En proposer plusieurs représentations.

RÉSOLUTION

On tape successivement les instructions suivantes avec le logiciel *Xcas* :

```
X:=[5.65,5.7,5.75,5.8,5.9,5.95];
E:=[8,28,27,9,21,7]; evalf(moyenne(X,E));
evalf(ecart_type(X,E));
median(X,E);quartile1(X,E); quartile3(X,E);
diagramme_batons(X,E); camembert(X,E);
moustache(X,E).
```

On obtient les résultats suivants : la série a pour moyenne 5,778, pour écart type 0,092 (arrondi à 10^{-3} près), pour médiane 5,75 et pour écart interquartile $5,9 - 5,7 = 0,2$. On propose trois représentations de cette série :



Méthode

• Avec une calculatrice CASIO Graph 35+

→ Dans le menu, aller sur l'icône **STAT** dans l'écran de démarrage. Mettre les valeurs de la variable X dans la liste intitulée **List1** et les valeurs des effectifs correspondants dans la liste intitulée **List2**.

→ Sélectionner **CALC** (touche F2) puis **SET** (touche F6). Entrer en paramètre de **1Var Xlist** : List1 et en paramètre de **1Var Freq** : List2. Valider par **EXE**.

→ Sélectionner **1Var** (touche F1) pour obtenir les caractéristiques de la série. Faire défiler ces caractéristiques à l'aide de la flèche vers le bas. En particulier, la moyenne est donnée par $\bar{x}$, l'écart type est donné par σn , la médiane par **Med**, le premier et le troisième quartiles par Q_1 et Q_3 . Revenir au menu **STAT** en sélectionnant **EXIT**.

→ Sélectionner **GRPH** (touche F1) puis **SET** (touche F6). Entrer en paramètre de **Graph Type** : Hist ou Box, en paramètre de **Xlist** : List1 et en paramètre de **Frequency** : List2. Valider par **EXE**. Sélectionner **GPH1** (touche F1) pour obtenir la représentation graphique souhaitée.

• Avec une calculatrice TI 89

→ Sélectionner avec les curseurs l'icône **Stats/Edit** dans l'écran de démarrage. Valider par **ENTER** et sélectionner le dossier courant **Main**. Mettre les valeurs de la variable X dans la liste intitulée **liste1** et les valeurs des effectifs correspondants dans la liste intitulée **liste2**.

→ Sélectionner l'icône **Stats/Edit** puis **Calc** (touche F4). Sélectionner l'onglet 1 : **Stats 1-Var** et valider par **ENTER**. Entrer en paramètre de **Liste** : liste1 et en paramètre de **Freq** : liste2. Valider par **ENTER** pour obtenir les caractéristiques de la série. Faire défiler ces caractéristiques à l'aide de la flèche vers le bas. En particulier, la moyenne est donnée par $\bar{X}$, l'écart type est donné par σX , la médiane par **MedX**, le premier et le troisième quartiles par $Q_1 X$ et $Q_3 X$. Revenir au menu **Stats/Edit** en sélectionnant **ENTER**.

→ Sélectionner **Graph** (touche F2) puis l'onglet 1 : **Config Graph....** Sélectionner ensuite **Choix** (touche F1) pour configurer Grap1. Entrer en paramètre de **Type Graphe** : Histogramme ou BoitMoust, en paramètre de **x** : liste1, en paramètre de **Util.freq et categories?** : OUI et en paramètre de **Freq** : liste2. Sélectionner **ZoomDonn** (touche F5) pour obtenir la représentation graphique souhaitée.

• Avec le logiciel Xcas

→ Créer deux listes : la liste X contient les valeurs de la variable X et la liste E contient les valeurs des effectifs correspondants.

→ Utiliser les commandes **moyenne**, **ecart_type**, **median**, **quartile1** et **quartile3** pour obtenir les caractéristiques de la série demandées. On peut utiliser la commande **evalf** pour obtenir une valeur approchée et non exacte des résultats.

→ Utiliser les commandes **diagramme_batons**, **camembert** ou **moustache** pour obtenir la représentation graphique souhaitée.



B Utiliser un logiciel ou une calculatrice pour représenter une série statistique à deux variables X et Y , en déterminer un ajustement affine et le coefficient de corrélation linéaire

On s'intéresse à l'évolution de la fréquentation des campings 4 étoiles ou plus en France métropolitaine.

Année	2004	2005	2006	2007	2008	2009	2010
Rang de l'année x_i	0	1	2	3	4	5	6
Fréquentation en milliers de nuitées y_i	25 156	26 470	28 295	28 897	30 063	31 212	32 014

1. Représenter le nuage de points associé à la série statistique $(x_i; y_i)$ pour i entier variant de 0 à 6.
2. Déterminer le coefficient de corrélation linéaire de la série statistique $(x_i; y_i)$. Arrondir à 10^{-3} .
3. Déterminer une équation de la droite de régression $\mathcal{D}$ de y en x , par la méthode des moindres carrés, sous la forme $y = ax + b$ où a et b sont à arrondir à 10^{-4} .


RÉSOLUTION

1., 2. et 3. On crée avec *GeoGebra* le tableau suivant :

Tableur			
	A	B	C
1	0	25156	(0, 25156)
2	1	26470	(1, 26470)
3	2	28295	(2, 28295)
4	3	28897	(3, 28897)
5	4	30063	(4, 30063)
6	5	31212	(5, 31212)
7	6	32014	(6, 32014)

Puis on tape $r = \text{CoeffCorrélation}[C1, C2, C3, C4, C5, C6, C7]$ et $\text{dreg} = \text{AjustLin}[C1, C2, C3, C4, C5, C6, C7]$ dans la ligne de saisie.

On obtient le coefficient de corrélation $r \approx 0,993$ et l'équation réduite de la droite de régression de y en x :



Méthode

• Avec le logiciel *GeoGebra*

- Dans le menu **Affichage**, sélectionner **Tableur**. Dans la colonne A, recopier les n valeurs prises par X . Dans la colonne B, recopier les n valeurs prises par Y .
- Taper $=A1,B1$ dans la cellule C1. Utiliser la poignée de copie pour copier cette formule vers le bas jusqu'à la cellule Cn.
- Pour visualiser le nuage, recadrer la fenêtre d'affichage. Pour cela, faire un clic droit sur la zone **Graphique** et aller dans **Graphique** puis dans **Basique**.
- Taper $r = \text{CoeffCorrélation}[\text{<Liste Points>}]$ dans la ligne de saisie, en spécifiant la liste des points et valider pour obtenir le coefficient de corrélation linéaire.
- Taper $\text{dreg} = \text{AjustLin}[\text{<Liste Points>}]$ dans la ligne de saisie, en spécifiant la liste des points et valider pour obtenir l'équation réduite de la droite de régression de Y en X .
- Par défaut, les nombres sont arrondis à 10^{-2} près par *GeoGebra*. Pour modifier la précision, sélectionner **Options** puis **Arrondi** et choisir le nombre de décimales qui convient.

• Avec une calculatrice **TI 89**

- Sélectionner avec les curseurs, **Stats/Edit** dans l'écran de démarrage. Valider par **ENTER** et sélectionner le dossier courant **Main**. Mettre les valeurs de la variable X dans la liste intitulée **liste1** et les valeurs de la variable Y dans la liste intitulée **liste2**.
- Sélectionner **Graph** (touche F2) choix **1: Config Graph**. Sélectionner le graphique **Graph1**. Sélectionner **Choix** (touche F1). Renseigner la boîte de dialogue en tapant $x:\text{liste1}$ $y:\text{liste2}$ et valider par **ENTER**. Sélectionner **ZoomDonn** (touche F5) pour obtenir le nuage de points.
- Sélectionner l'icône **Stats/Edit** puis **Calc** (touche F4). Sélectionner l'onglet **3: Régressions** puis l'onglet **2: RegLin(ax+b)** et valider par **ENTER**. Saisir ensuite **liste1** et à la ligne **liste2** et enregistrer l'équation en $y1(x)$. Valider par **ENTER** pour obtenir les valeurs de a et b et du coefficient de corrélation (donné par r ou par corr). Valider par **ENTER**. Pour obtenir le tracé, sélectionner **GRAPH** (touche F3).

• Avec une calculatrice **CASIO Graph 35+**

- Dans le menu, aller sur l'icône **STAT** dans l'écran de démarrage. Mettre les valeurs de la variable X dans la liste intitulée **List1** et les valeurs de la variable Y dans la liste intitulée **List2**.
- Sélectionner **GRPH** (touche F1) puis encore **F1** pour obtenir le nuage de points.
- Sélectionner l'onglet **X** (touche F1) pour obtenir les valeurs de a et b et du coefficient de corrélation (donné par r). Taper ensuite **F5: COPY en Y1**. Valider par **EXE** puis sélectionner **DRAW** (touche F6) pour obtenir le tracé.

Travaux pratiques

TP1



Comment comparer la qualité de deux ajustements, interpoler et extrapoler ?

Pour les besoins d'une usine qui fabrique des puces, l'entreprise Terrare extrait du minerai rare. Sa production annuelle (en tonnes) n'excède pas 2 t et le coût total annuel de la production est noté en milliers d'euros (on notera $1 \text{ k€} = 10^3 \text{ €}$).

Les résultats des premières années d'exploitation sont consignés dans les trois premières lignes du tableau ci-dessous.

Année	2006	2007	2008	2009	2010
x_i	0,52	0,77	1,01	1,36	1,81
y_i	186,7	230,9	283,1	381,3	558,9
z_i					

A Représenter le nuage de points associé à cette série statistique dans un repère orthogonal d'unités graphiques : 1 cm pour 0,1 unité sur l'axe des abscisses et 2 cm pour 100 unités sur l'axe des ordonnées.

B On veut déterminer un ajustement linéaire de la série.

- À l'aide de la calculatrice ou d'un logiciel, déterminer par la méthode des moindres carrés, une équation de la droite d'ajustement de y en x . Les coefficients seront arrondis à 10^{-2} .
- À l'aide de la calculatrice ou d'un logiciel, déterminer le coefficient de corrélation linéaire de la série. On arrondira à 10^{-3} .

C On souhaite déterminer un ajustement exponentiel de la série. Pour cela, on pose $z = \ln y$.

- Compléter la quatrième ligne du tableau précédent. On arrondira à 10^{-3} les valeurs de z_i .
- À l'aide de la calculatrice ou d'un logiciel, déterminer le coefficient de corrélation linéaire entre x et z .
- Comparer le coefficient de corrélation linéaire entre x et y avec le coefficient de corrélation linéaire entre x et z . Que peut-on en conclure ?
- À l'aide de la calculatrice, déterminer par la méthode des moindres carrés, une équation de la droite d'ajustement de z en x . Les coefficients seront arrondis à 10^{-2} .
- En déduire une expression de y en fonction de x , de la forme $y = Be^{ax}$. Arrondir B à l'entier le plus proche.

D Interpolation

Utiliser l'ajustement exponentiel de la question précédente pour déterminer une estimation du coût de production pour 1,5 t.

E Extrapolation

Utiliser l'ajustement exponentiel de la question C pour déterminer une estimation du coût de production pour 2 t.

TP2



Comment quantifier la qualité de l'ajustement d'une distribution statistique par la droite de Henry ?

A Principe : utiliser la technique de la régression linéaire selon les moindres carrés pour quantifier la qualité de l'ajustement d'une distribution statistique observée avec celle d'une loi normale.

Contexte probabiliste : si X est une variable aléatoire suivant la loi $\mathcal{N}(\bar{X}; \sigma)$, alors $T = \frac{X - \bar{X}}{\sigma}$ suit la loi $\mathcal{N}(0; 1)$.

Statistiquement : on note x_i les valeurs de la distribution statistique et f_i les fréquences cumulées correspondantes. Les valeurs des fréquences cumulées croissantes peuvent être apparentées à la fonction de répartition de la loi normale.

Soit t_i la valeur donnée par lecture inverse de la table de la loi $\mathcal{N}(0; 1)$ associée à f_i . Si la distribution statistique est extraite d'une population normale, le nuage de points $(x_i; t_i)$ devrait donc être ajusté par la droite d'équation $t = \frac{x - \bar{X}}{\sigma}$, appelée **droite de Henry**.

B Une entreprise fabrique des pieds métalliques pour des tables. Dans la production d'une journée, on étudie un échantillon de 120 pieds dont on mesure les longueurs. On obtient la série suivante :

Longueur (en mm)	699,4	699,6	699,8	700,0	700,2	700,4	700,6
Effectif	3	18	12	46	20	19	2

On se demande si on peut ajuster la distribution de la longueur des pieds à une loi normale. Pour cela, on utilise le logiciel *GeoGebra*.

- Dans le menu **Affichage**, sélectionner **Tableur**. Dans la colonne A, recopier les sept valeurs de longueurs, que l'on nomme x_i pour i allant de 1 à 7. Dans la colonne B, recopier les valeurs des effectifs correspondants.
- En colonne C, calculer les fréquences correspondantes. Pour cela, taper **=B1/120** dans la cellule C1.

Utiliser la poignée de recopie pour copier cette formule vers le bas jusqu'à la cellule C7.

3. En colonne D, calculer les fréquences cumulées croissantes f_i pour i allant de 1 à 7. Pour cela, taper $=C1$ dans la cellule D1, puis $=C1+B2$ dans la cellule D2 et utiliser la poignée de recopie pour copier cette formule vers le bas jusqu'à la cellule D7.

4. En colonne E, on applique la loi normale inverse aux valeurs de la colonne D pour obtenir les valeurs t_i pour i allant de 1 à 7. Ainsi, taper $=InverseNormale[0,1,D1]$ dans la cellule E1 et utiliser la poignée de recopie pour copier cette formule vers le bas jusqu'à la cellule E7.

5. Expliquer pourquoi GeoGebra renvoie la réponse ∞ en cellule E7.

6. En colonne F, on crée la liste des points $(x_i; t_i)$ pour i allant de 1 à 6. Taper $=(A1,E1)$ dans la cellule F1. Utiliser la poignée de recopie pour copier cette formule vers le bas jusqu'à la cellule F6. Pour visualiser le nuage, recadrer la fenêtre d'affichage.

	A	B	C	D	E	F
1	699.4	3	0.025	0.025	-1.96	(699.4, -1.96)
2	699.6	18	0.15	0.175	-0.9346	(699.6, -0.9346)
3	699.8	12	0.1	0.275	-0.5978	(699.8, -0.5978)
4	700	46	0.3833	0.6583	0.4079	(700, 0.4079)
5	700.2	20	0.1667	0.825	0.9346	(700.2, 0.9346)
6	700.4	19	0.1583	0.9833	2.128	(700.4, 2.128)
7	700.6	2	0.0167	1	∞	


7. Déterminer, par la méthode des moindres carrés, une équation de la droite de Henry (droite d'ajustement de t en x). Les coefficients seront arrondis à 10^{-3} .

8. À l'aide de la calculatrice ou d'un logiciel, déterminer le coefficient de corrélation linéaire de la série. On arrondira à 10^{-3} .

C Exploitation

La valeur du coefficient de corrélation $r \approx 0,991$ justifie l'ajustement de la distribution des longueurs à une distribution normale.

On a $\frac{1}{\sigma} \approx 3,865$ et $\frac{\bar{X}}{\sigma} \approx 2\,704,943$, donc σ est estimé à 0,26 mm et $\bar{X}$ à 700,58 mm.



TP3

Comment interpréter l'existence d'une corrélation entre deux événements ?

Une étude statistique a montré une forte corrélation entre la présence des cigognes dans les villages d'Alsace et le taux de naissance des enfants, démontrant ainsi que le lien entre ces oiseaux et les bébés n'est pas le fait du hasard. On sait bien sûr que ce qui est en cause ici ne sont pas les chiffres, qui sont corrects, mais l'interprétation erronée qui peut en être faite, appelée « effet cigogne ». Qu'il y ait corrélation entre les deux événements ne signifie nullement que l'un est la cause de l'autre. Dans ce cas, il est évidemment connu d'une part que les cigognes préfèrent nidifier sur les cheminées calmes des petits hameaux tranquilles et, d'autre part, que la natalité est plus grande en milieu rural qu'en milieu urbain. Cela est tout simplement l'illustration qu'un fort coefficient de corrélation n'induit pas obligatoirement une relation de causalité entre deux phénomènes mesurés qui pourraient tout à fait être corrélés à une troisième variable non mesurée dont dépendent les deux autres.

En s'inspirant du raisonnement précédent, répondre aux questions ci-après.

A Il existe une corrélation entre utilisation de crème solaire et cancer de la peau. Peut-on en conclure qu'il ne faut plus utiliser de crème solaire lorsque l'on va à la plage ?

B Le nombre d'écoles maternelles dans une ville est corrélé au nombre de crimes et délits. Peut-on en conclure que repousser les écoles en banlieue sauverait des vies ?

C Des chercheurs de la faculté de médecine de l'Université de Pittsburgh, en Pennsylvanie, ont déterminé le temps passé à regarder la télévision, devant un ordinateur, à jouer à des jeux vidéo notamment, ou à écouter la radio, de 4 142 adolescents qui ne souffraient pas de dépression au début de l'étude en 1995. Ils ont alors constaté que des risques nettement plus grands de dépression étaient corrélés avec le nombre d'heures passées devant la télévision ou les jeux vidéo. Peut-on en conclure que le fait de consacrer un long moment à regarder la télévision ou à jouer à des jeux vidéo contribue au développement de symptômes dépressifs ?

Exercices et problèmes

Pour s'entraîner → CORRIGÉS, p. 247


Série statistique à une variable

1 **  Une entreprise fabrique des conserves alimentaires dont l'étiquette annonce une masse de 250 g. Les masses obtenues pour un échantillon de 500 conserves prises au hasard sont données dans le tableau suivant :

Masse (en g)	[235; 240]	[240; 245]	[245; 250]	[250; 255]	[255; 260]
Nombre de conserves	33	67	217	132	51

- À l'aide de la calculatrice, calculer, en utilisant les milieux des classes, la masse moyenne ainsi que l'écart type σ des conserves de cet échantillon. On fournira les valeurs arrondies au dixième.
- Calculer le pourcentage des conserves alimentaires dont la masse présente un écart avec la moyenne supérieur à l'écart type.
- Représenter cette série statistique à l'aide d'un diagramme circulaire.

2 *  Un artisan fabrique des boules en bois de diamètre 50 mm, destinées à un fabricant de jouets. Après tournage, les boules sont matées et polies dans des rouleaux. C'est ensuite que sont contrôlés leurs diamètres. On prélève au hasard dans la production hebdomadaire de l'artisan un échantillon de 100 boules que l'on passe au crible pour les calibrer. Les résultats sont résumés dans l'histogramme donné ci-dessous.



- Dresser un tableau des diamètres regroupés en classes d'amplitude 0,2, avec les effectifs et les centres des classes.
- Calculer à 10^{-2} près la moyenne m et l'écart type σ de cette série.
- Montrer que plus de 90 % des boules ont un diamètre compris dans l'intervalle $[m - 2\sigma; m + 2\sigma]$.

3 **  On a relevé, pendant 30 jours consécutifs, le nombre d'entrées dans deux salles de sports.


On a obtenu les résultats suivants :

Salle 1 : 219, 259, 225, 227, 236, 190, 240, 269, 229, 236, 238, 231, 192, 210, 225, 222, 241, 203, 214, 209, 217, 213, 216, 206, 175, 229, 242, 243, 226, 266.

Salle 2 : 262, 246, 212, 231, 229, 228, 216, 213, 222, 235, 210, 264, 185, 211, 232, 229, 170, 223, 226, 223, 197, 260, 228, 250, 246, 174, 224, 207, 205, 220.

- Comparer les dispersions de ces deux séries autour de leur moyenne.
- Dresser, pour chaque salle, un tableau des nombres d'entrées regroupés en classes d'amplitude 10, avec les effectifs et les centres des classes.
- Représenter les histogrammes correspondant à ces deux tableaux.


4 * Dans une usine de fabrication d'ampoules de 20 W, on a prélevé 200 ampoules et mesuré leur puissance. Les données collectées ont permis de réaliser le diagramme en boîte ci-dessous.



Préciser, dans chaque cas, si les affirmations suivantes sont vraies ou fausses.

- Au moins 100 ampoules ont une puissance comprise entre 19,3 W et 21 W.
- La puissance moyenne des 200 ampoules est 20 W.
- Au moins 150 ampoules ont une puissance effective de 21 W.

5 * On considère deux associations culturelles, appelées A et B, qui ont le même effectif : 32 membres. Voici les diagrammes en boîte du nombre de films vus au cinéma dans l'année pour chacune de ces associations, en plaçant aux extrémités le maximum et le minimum.




Chaque assertion suivante est-elle vraie ou fausse ?

- Dans l'association A, environ la moitié des membres a vu moins de neuf films au cinéma.
- Dans l'association B, environ huit membres ont vu dix films ou plus au cinéma.
- Au moins la moitié des membres de l'association A a vu plus de films au cinéma que les trois quarts des membres de l'association B.

d. Environ le quart des membres de l'association B a vu moins de films au cinéma que chaque membre de l'association A.

6 **  Un jardinier a deux lots de bulbes de tulipes A et B de provenances différentes. Il a pesé un à un tous les bulbes. Le diagramme en boîte ci-dessous résume les résultats des masses en grammes des bulbes du lot A.



- À partir de ce diagramme, donner les valeurs du premier et du troisième quartiles, de la médiane et des extremums.
- Estimer le pourcentage de bulbes dont la masse est supérieure ou égale à 40 g.
- Donner l'écart interquartile et donner une interprétation de ce résultat.
- Pour le lot B, voici le tableau des effectifs :

Masse (en g)	20	25	30	35	40	45	50	55	60
Nombre de bulbes	10	14	22	25	18	12	8	6	5

- Quel est le pourcentage de bulbes dont la masse est strictement comprise entre 25 et 55 g (résultat arrondi à 1% près) ?
- Déterminer la masse moyenne au gramme près des bulbes du lot B. Déterminer la médiane, les premier et troisième quartiles.
- Tracer le diagramme en boîte du lot B.
- Lequel des deux lots semble le mieux calibré ? Justifier la réponse.

7 **  Voici les notes obtenues par 200 candidats au QCM d'entrée (session 2009) de l'école d'ingénieurs ESIEE à Amiens :

Notes	0	1	2	3	4	5	6	7	8	9	10
Effectif	1	3	5	11	17	9	7	2	1	3	7

Notes	11	12	13	14	15	16	17	18	19	20
Effectif	13	20	19	16	19	16	13	9	6	3

- À l'aide de la calculatrice, calculer les indicateurs de cette série de notes.
- Proposer deux couples d'indicateurs susceptibles de résumer cette série de notes.
- Comparer la note moyenne et la note médiane de cette série statistique. Que remarque-t-on ?
- Construire le diagramme en bâtons de cette série de notes. Quelles observations peut-on faire ?

- Les deux couples évoqués dans la question 2 ont-ils la même pertinence pour résumer cette série ?
- Construire le diagramme en boîte de cette série.

Série statistique à deux variables

8 **  Les normes de résistance sont établies par coulage de béton à l'intérieur d'éprouvettes de test pouvant être, selon les pays, de forme cubique ou cylindrique. On constate que la résistance d'un même béton, mesurée sur une éprouvette cubique, est plus élevée que sa résistance mesurée sur une éprouvette cylindrique. Par exemple, la norme 30/37 fait référence à une résistance de 30 MPa (mégapascal) sur cylindrique et de 37 MPa sur cubique. Le tableau suivant donne en correspondance les résistances mesurées pour divers types de béton.

Valeurs de x (éprouvette cylindrique)	20	30	40	50	60	70	80
Valeurs de y (éprouvette cubique)	25	37	50	60	75	85	95

- Donner à 0,001 près le coefficient de corrélation linéaire de la série statistique double $(x; y)$ et expliquer pourquoi un ajustement affine semble justifié dans ce cas.
- Déterminer une équation de la forme $y = ax + b$ de la droite de régression $\mathcal{D}$ de y par rapport à x . On donnera les valeurs de a et b à 0,01 près.
- On conçoit un béton ayant une résistance de 120 MPa sur éprouvette cubique. Quelle est la norme que l'on peut prévoir indiquer pour celui-ci ?

9 **  L'évolution du SMIC mensuel exprimé en euros entre 2006 et 2011, et arrondi à l'entier, est donnée dans le tableau suivant :

Année x_i	2006	2007	2008	2009	2010	2011
SMIC mensuel y_i	1 254	1 280	1 321	1 338	1 348	1 365

- À l'aide d'un logiciel ou d'une calculatrice, visualiser le nuage de points associé à cette série.
- Déterminer les coordonnées du point moyen G .
- Déterminer l'équation réduite de la droite d'ajustement du nuage de points $(x_i; y_i)$ par la méthode des moindres carrés. On arrondira les coefficients à trois décimales.
- Montrer que la droite passe par le point de coordonnées (2005; 1 240).
- En utilisant l'ajustement de la question précédente, estimer la valeur du SMIC mensuel en 2015 (arrondir à l'entier) et déterminer à partir de quelle année le SMIC mensuel dépassera 1 500 €.

Exercices et problèmes

10 ★★  Une salle de théâtre contient 2 000 places assises. Lors du lancement d'un nouveau spectacle, le directeur s'attend à ce que le nombre de spectateurs augmente au fil du temps et note chaque jour le nombre de personnes souhaitant y assister. Les résultats sont consignés dans le tableau suivant.

Rang du jour x_i	1	2	3	4	5	6	7
Nombre de spectateurs y_i	975	1 025	1 100	1 225	1 275	1 350	1 450

1. Calculer le pourcentage d'évolution du nombre de spectateurs entre le premier et le septième jour de représentation. On arrondira le résultat au dixième.
2. Dans un repère orthogonal et sur une feuille de papier millimétré, représenter le nuage de points associé à cette série statistique. On prendra pour unités: 2 cm pour 1 jour en abscisse et 1 cm pour 50 spectateurs en ordonnée en commençant les graduations de l'axe des ordonnées à 800.

3. La forme du nuage permet-elle d'envisager un ajustement affine? Pourquoi? Confirmer la pertinence de l'ajustement affine par la détermination, à l'aide de la calculatrice ou d'un logiciel, du coefficient de corrélation linéaire de la série statistique double.

4. Calculer les coordonnées du point moyen G de ce nuage et placer G sur le graphique précédent.

5. Donner, à l'aide de la calculatrice ou d'un logiciel, l'équation réduite de la droite $\mathcal{D}$ d'ajustement de y en x obtenue par la méthode des moindres carrés. On arrondira les valeurs numériques obtenues au dixième. Construire cette droite $\mathcal{D}$ sur le graphique précédent.

6. On admet dans cette question que la tendance se poursuit suivant le modèle établi dans la question précédente.

a. Combien le directeur peut-il prévoir de spectateurs le dixième jour de représentation du spectacle?

b. Au bout de combien de jours la salle affichera-t-elle complet? Combien de personnes le directeur devra-t-il alors refuser ce jour-là?


Pour maîtriser

11 ★★  Le tableau ci-dessous donne le nombre de naissances (en milliers) par an en France métropolitaine entre 1901 et 1920.

Année	Nombre de naissances (en milliers)	Année	Nombre de naissances (en milliers)
1901	917,1	1911	793,5
1902	904,4	1912	801,6
1903	884,5	1913	795,9
1904	877,1	1914	757,9
1905	865,6	1915	483,0
1906	864,7	1916	384,7
1907	829,6	1917	412,7
1908	849,0	1918	472,8
1909	824,7	1919	507,0
1910	828,1	1920	838,1

1. a. Donner le nombre moyen de naissances par an en France métropolitaine entre 1901 et 1920. Arrondir la réponse à la centaine.
- b. Donner la médiane, les premier et troisième quartiles de cette série statistique.
- c. Construire le diagramme en boîte de cette série statistique.

2. Le diagramme en boîte de la série statistique du nombre annuel de naissances (en milliers) entre 1981 et 2000 est donné ci-après :



a. Lire et donner la médiane, les premier et troisième quartiles de la série statistique du nombre annuel de naissances (en milliers) entre 1981 et 2000.

b. Déterminer l'étendue de cette série.

3. Les phrases suivantes sont-elles vraies ou fausses?

a. Entre 1981 et 2000, le nombre annuel de naissances est supérieur à 760 000 pendant plus de 16 ans.

b. L'étendue du nombre annuel de naissances est plus de cinq fois plus élevée entre 1901 et 1920 qu'entre 1981 et 2000.

12 ★★   La Fédération française de franchise a publié le nombre de franchisés établis en France entre 2000 et 2005. Le tableau suivant, où t_i désigne le rang de l'année, donne, en milliers, le nombre y_i de ces franchisés, au premier janvier de chaque année.

Année	2000	2001	2002	2003	2004	2005
Rang de l'année t_i	1	2	3	4	5	6
Nombre de franchisés y_i	30,63	31,781	33,26	34,745	36,773	39,51


1. Recopier le tableau précédent en y ajoutant une ligne où l'on calculera $x_i = t_i^2$.
2. Déterminer, à l'aide d'une calculatrice ou d'un logiciel, le coefficient de corrélation linéaire de la série statistique de variables x et y . Arrondir à 10^{-2} .
3. Déterminer, à l'aide d'une calculatrice ou d'un logiciel, une équation de la droite de régression de y en x , sous la forme $y = ax + b$, où a et b sont à arrondir à 10^{-3} .
4. En déduire une expression de y en fonction de t .
5. À l'aide de la question précédente, donner une estimation du nombre de franchisés installés en France au 1^{er} janvier 2008 et estimer l'année au cours de laquelle, le nombre de franchisés installés en France dépassera, pour la première fois, les 60 000.

13 *** TICE Avant une greffe de cornée, la cornée prélevée est plongée dans un liquide physiologique afin de provoquer l'évacuation du surplus d'eau contenu dans le tissu. On étudie l'évolution dans le temps de l'épaisseur de la cornée. Une étude expérimentale de l'épaisseur de la cornée, exprimée en micromètres, en fonction du temps, exprimé en heures, a permis d'obtenir le tableau suivant :

t	0	1	2	3	4	5
y	983	786	700,64	622,08	645,22	637,83

t	6	7	8	9	10
y	634,57	633,13	632,5	632,22	632,1

Le nuage des points de coordonnées $(t; y)$ correspondant est représenté sur le graphique suivant :



1. À l'aide du graphique et sans calcul, expliquer pourquoi un ajustement affine de y en t n'est pas approprié.
2. Recopier le tableau précédent en y ajoutant une ligne où l'on calculera $z = \ln(y - 632)$. Les valeurs approchées seront arrondies à 10^{-2} .
3. Donner une équation de la droite de régression de z en t , obtenue par la méthode des moindres carrés, sous la forme $z = at + b$, où a et b sont à arrondir à 10^{-2} .

4. En déduire une expression de y en fonction de t , selon cet ajustement.
5. À l'aide du résultat de la question 4, donner une estimation de l'épaisseur de la cornée au bout de 12 h.

14 *** TICE On considère deux variables statistiques X et Y . Lorsque l'on réalise un ajustement affine par la méthode des moindres carrés, on privilégie soit la régression linéaire de Y en X , soit la régression linéaire de X en Y , créant ainsi une dissymétrie entre les deux variables. En fait, on choisit la première ou la seconde selon le bon sens, l'importance des relations et le type de relation qui paraît plus logique ou plus clair. En particulier, lorsque l'une des deux variables est un numéro d'ordre, celui-ci sera placé en X puisqu'on cherche à savoir comment évolue Y en fonction de cet ordre. Les deux droites de régression correspondent au même coefficient de corrélation linéaire. On va vérifier ce résultat sur l'exemple de l'exercice résolu B.

1. On a obtenu la droite de régression de Y en X d'équation réduite suivante : $y = 1\,136,6429x + 25\,462,5$.

Exprimer x en fonction de y . En déduire l'équation réduite de la droite de régression de X en Y .

2. Calculer le coefficient de corrélation linéaire de la série statistique $(y_i; x_i)$ et le comparer à celui obtenu dans l'exercice résolu B.

15 *** TICE CORRIGÉ, p. 247 La durée de vie, exprimée en heures, d'une ampoule halogène définit une variable aléatoire X .

L'étude de la durée de vie de 500 de ces ampoules a permis d'obtenir l'historique suivant :

Temps de fonctionnement x_i	500	700	900	1100	1300	1500	1700
Effectifs n_i	24	67	108	126	109	51	15

Reprendre les techniques développées dans le TP2 pour répondre aux questions ci-dessous.

1. Créer un tableau contenant les valeurs x_i , n_i , les fréquences cumulées croissantes f_i et les valeurs t_i , données par lecture inverse de la table de la loi $\mathcal{N}(0; 1)$ associée à f_i .
2. Représenter graphiquement le nuage de points $(x_i; t_i)$.
3. Obtenir l'équation réduite de la droite de Henry et le coefficient de corrélation linéaire.
4. Exploiter ces calculs pour montrer que l'on peut ajuster la distribution de la durée de vie des ampoules à une loi normale dont on précisera les paramètres à 10^{-1} près.

Pour se préparer au BTS

16 ***  Les données du tableau ci-dessous concernent l'évolution de la part d'énergie renouvelable dans la production annuelle d'électricité de l'Union européenne, pour la période allant de 2003 à 2008. (Source, Eurostat-Énergie)

	A	B	C	D	E	F	G
1	Année	2003	2004	2005	2006	2007	2008
2	Rang de l'année (x_i)	0	1	2	3	4	5
3	Part d'énergie renouvelable dans la production d'électricité de l'Union européenne, en % (y_i)	12,9	13,9	14	14,6	15,5	16,7
4	Taux annuel d'évolution de la production d'électricité de l'Union européenne, en %		7,8				

PARTIE A

- Quelle formule doit-on entrer dans la cellule C4 et recopier sur la plage D4:G4 pour obtenir les taux annuels d'évolution de la production d'électricité de l'Union européenne, en % ? Compléter le tableau.
- Déterminer le taux d'évolution global de la part d'énergie renouvelable dans la production d'électricité de l'Union européenne entre 2003 et 2008. On arrondira le résultat à 0,1 % près.
- Déterminer le taux annuel moyen d'évolution entre 2003 et 2008, arrondi à 0,1 % près.

PARTIE B

- En utilisant la calculatrice ou un logiciel, donner une équation de la droite $\mathcal{D}$ qui réalise un ajustement affine du nuage de points $M_i(x_i; y_i)$ par la méthode des moindres carrés. On arrondira à 10^{-3} près.
- À l'aide de la calculatrice, donner le coefficient de corrélation entre x et y à 10^{-3} près.

PARTIE C

Soit u_n la suite géométrique de premier terme $u_0 = 12,9$ et de raison 1,053. On suppose que u_n représente le pourcentage de la part d'énergie renouvelable dans la production d'énergie de l'Union européenne l'année $2003 + n$, n étant inférieur ou égal à 9.

- Exprimer u_{n+1} en fonction de u_n .
- Exprimer u_n en fonction de n .
- a. Calculer u_9 . On arrondira le résultat à 10^{-1} près.
b. Que représente u_9 ?

PARTIE D

On se demande si la part d'énergie renouvelable dans la production d'électricité de l'Union européenne peut atteindre l'objectif de 21 % en 2012. L'un ou l'autre des deux modèles étudiés conduit-il à cet objectif ?

17 ***  Une entreprise d'agencement fabrique des tables. Une des machines débite les pieds des tables.

PARTIE A

Dans la production d'une journée, on étudie un échantillon de 200 pieds, dont on mesure les longueurs. On obtient la série suivante :

Longueur (en cm)	[70,6 ; 70,7[	[70,7 ; 70,8[	[70,8 ; 70,9[	[70,9 ; 71,0[
Effectifs	2	6	20	40
Longueur (en cm)	[71,0 ; 71,1[	[71,1 ; 71,2[	[71,2 ; 71,3[	[71,3 ; 71,4[
Effectifs	48	48	32	4

- Calculer, à 0,1 mm près, la longueur moyenne et l'écart type de cette série.
- Un pied de table n'est pas utilisable si sa longueur est inférieure à 70,8 cm. Quel est dans cet échantillon le pourcentage de pieds défectueux ?

PARTIE B

La longueur moyenne des pieds peut varier d'un jour à l'autre. La fabrication est jugée acceptable tant que la longueur moyenne des pieds est supérieure ou égale à 70,8 cm. Le tableau suivant contient les longueurs moyennes, en cm, des pieds au cours des sept premiers jours de fabrication.

Jour x_i	0	1	2	3	4	5	6
Longueur moyenne y_i	71	70,99	70,98	70,97	70,95	70,92	70,90

- Représenter le nuage des points $M_i(x_i; y_i)$ dans un repère orthogonal, avec pour unités : 2 cm pour 1 jour en abscisse et 1 cm pour 0,1 cm (commencer la graduation à 70,0 cm) en ordonnée.
- Un ajustement affine de ce nuage de points semble-t-il approprié ? Justifier.
- À l'aide de la calculatrice ou d'un logiciel, donner le coefficient de corrélation entre x et y à 10^{-2} près et une équation de la droite de régression de y en x par la méthode des moindres carrés (arrondir les coefficients à 4 décimales).
- À l'aide de cette équation de droite, déterminer au bout de combien de jours il faudra à nouveau régler la machine.