

# Chapitre 10: Échantillonnage.


## Introduction:

Pourquoi travailler avec des échantillons ? Deux choses :

- L'étude détruit l'individu (ex : on s'intéresse à la durée de vie d'une ampoule, mieux vaut tester une petite quantité, un échantillon, que la totalité produite)
- La population est trop grande pour que l'étude soit réalisable.

Dans ce cas là, on parlera de statistique inférentielles. C'est à dire qu'on s'intéresse à la détermination des paramètres d'une population complète à partir de ceux d'un échantillon.

Dans la cas inverse, l'échantillonnage statistique consiste à prédire, à partir d'une population connue, les caractéristiques des échantillons qui en seront prélevés.



**Problématique :** On lance 100 fois une pièce de monnaie. Le côté pile est apparu 61 fois. Peut on dire que la pièce est truquée ?

## I- Fluctuation d'échantillonnage.

**Définition :** On appelle **échantillon** de taille  $n$ , la liste des résultats obtenus par  $n$  répétitions d'une même expérience aléatoire.

On s'intéresse au nombre de fois où le caractère prend une certaine valeur prédéfinie à l'avance.

**Exemple :** Dans notre exemple, on s'intéresse à la fréquence d'apparition de la face pile sur 100 échantillons de taille 100.

On remarque que la fréquence varie d'un échantillon à un autre. C'est ce qu'on appelle la fluctuation d'échantillonnage.

**Définition :** Lorsque l'on répète plusieurs fois la même expérience, la distribution des fréquences observées de l'événement « le caractère prend la valeur choisie » varie. On parle alors de **fluctuation d'échantillonnage**.

D'après la loi faible des grands nombres, la fréquence observée tend vers la probabilité théorique de l'événement considéré.

Maintenant, on s'intéresse à la manière dont ces fluctuations sont établies.

## II- Intervalle de fluctuation d'une proportion ou fréquence.

**Définition :** Un intervalle de fluctuation  $I$  des fréquences observées au seuil de 95 % est tout intervalle :

- contenant  $p$ , la fréquence théorique de ce que l'on observe.
- $P(f_n \in I) \geq 0,95$  où  $f_n$  est la fréquence observée au  $n$ -ième échantillon.

On peut également choisir un seuil de 90 % ou 99 %. Cela dépend de l'importance de la situation que l'on étudie.

## Comment déterminer cet intervalle ?

### x Avec la loi binomiale.

**Propriété :** L'intervalle de fluctuation au seuil 95 % d'une proportion, observée, sur un échantillon de taille  $n$ , d'une variable aléatoire  $X$  suivant une loi binomiale de paramètre  $n$  et  $p$  est l'intervalle  $\left[\frac{a}{n}; \frac{b}{n}\right]$  tel que :

- $a$  est le plus petit entier tel que  $P(X \leq a) > 0,025$  et
- $b$  est le plus petit entier tel que  $P(X \leq b) > 0,975$

Voir fiche méthode 34 p199

**Exemple.** Un joueur de tennis confirmé sert une première balle bonne 6 fois sur 10.  
Déterminer, en utilisant la loi binomiale, l'intervalle de fluctuation de la proportion des premières balles bonnes sur une série de 25 engagements.

On note  $X$  la variable aléatoire prenant pour valeur le nombre de premières balles bonnes sur 25 engagements.

$X$  suit la loi binomiale de paramètres  $n = 25$  et  $p = 0,6$ .

L'intervalle de fluctuation de la proportion de premières balles bonnes sur 25 engagements au seuil de 95 % est :

$$I = \left[ \frac{a}{n}; \frac{b}{n} \right],$$

où  $a$  est le plus petit entier tel que  $P(X \leq a) > 0,025$  ;

et  $b$  est le plus petit entier tel que  $P(X \leq b) \geq 0,975$ .

Pour déterminer  $a$  et  $b$ , on utilise la table des probabilités cumulées croissantes  $P(X \leq k)$  de la loi  $\mathcal{B}(25; 0,6)$ .

On obtient cette table de valeurs à l'aide d'une calculatrice.

#### Avec la calculatrice TI 82 stats.fr ou 83 Plus.fr

On tape  $\boxed{\text{f(x)}}$ , sur la ligne  $\text{Y1=}$  on tape  $\boxed{2\text{nde}} \boxed{\text{var}}$  pour distrib.

On sélectionne  $\text{A:binomFRép(}$   $\boxed{\text{entrer}}$  et on complète la ligne  $(25, 0.6, X)$   $\boxed{\text{entrer}}$

Pour obtenir la table on tape  $\boxed{2\text{nde}} \boxed{\text{graphe}}$ .

On obtient l'écran suivant :

| X  | Y1     |
|----|--------|
| 7  | .00121 |
| 8  | .00452 |
| 9  | .01317 |
| 10 | .03438 |
| 11 | .07788 |
| 12 | .15377 |
| 13 | .26772 |

#### Avec la calculatrice Casio Graph 35+

On tape  $\boxed{\text{MENU}}$ , on sélectionne  $\boxed{\text{STAT}} \boxed{\text{EXE}}$ .

Dans  $\text{List1}$  on saisit les valeurs prises par  $X$  : 0, 1, 2, 3 ... 25.

On tape  $\boxed{\text{F5}}$  pour  $\boxed{\text{DIST}}$ ,  $\boxed{\text{F5}}$  pour  $\boxed{\text{BINM}}$ ,  $\boxed{\text{F2}}$  pour  $\boxed{\text{Bcd}}$ ,  $\boxed{\text{F1}}$  pour  $\boxed{\text{List}}$ .

Sur la ligne  $\text{Numtrial}$ , on saisit 25  $\boxed{\text{EXE}}$ .

Sur la ligne  $\text{P}$  on saisit 0.6  $\boxed{\text{EXE}}$ .

On sélectionne  $\boxed{\text{Execute}} \boxed{\text{EXE}}$ .

On obtient l'écran suivant :

| Binomial C.D  |        |
|---------------|--------|
| 10            | 0.0131 |
| 11            | 0.0344 |
| 12            | 0.0779 |
| 13            | 0.1538 |
| 14            | 0.2677 |
| 0.03439151809 |        |

Attention ! Sur la ligne 11 on lit  $P(X \leq 10)$ .

On peut aussi utiliser un tableur ou le logiciel Sine Qua Non.

### x Avec la loi binomiale approchée par une loi normale.

**Rappel :** si  $n \geq 50$  et  $np(1-p) > 10$  on peut alors approcher une loi binomiale par une loi normale.

**Propriété :** La variable aléatoire  $F$  qui, à tout échantillon aléatoire prélevé avec remise et de taille  $n$ , associe la proportion du caractère considéré dans l'échantillon suit approximativement la loi normale  $N\left(p; \frac{p(1-p)}{n}\right)$

**Propriété :** L'intervalle de fluctuation de  $f$  au seuil  $1-\alpha$  est donné par :


$I = [p - u_\alpha \sqrt{\frac{p(1-p)}{n}}; p + u_\alpha \sqrt{\frac{p(1-p)}{n}}]$ , avec  $u_\alpha$  l'unique réel tel que  $P(-u_\alpha \leq Z \leq u_\alpha) = 1-\alpha$  où  $Z$  suit une loi normale  $N(0;1)$ .

### Valeurs à connaître :

- Si  $\alpha=0,01 \Rightarrow 1-\alpha=0,99 \Rightarrow u_\alpha=2,58$
- Si  $\alpha=0,05 \Rightarrow 1-\alpha=0,95 \Rightarrow u_\alpha=1,96$
- Si  $\alpha=0,1 \Rightarrow 1-\alpha=0,9 \Rightarrow u_\alpha=1,645$ .

### Règle de décision

- La détermination d'un intervalle de fluctuation permet de prendre une décision lorsqu'on fait une hypothèse sur une proportion ou une probabilité dans une population.
- En effet, en faisant une hypothèse sur la proportion  $p$  d'un caractère dans une population, on peut déterminer un intervalle de fluctuation  $I$  à 95 % de la fréquence de ce caractère dans un échantillon aléatoire de taille  $n$  : la fréquence observée dans un échantillon prélevé dans la population appartient à  $I$  dans au moins 95 % des cas.
- Ainsi, on établira une **règle de décision** : si la fréquence observée dans l'échantillon n'appartient pas à  $I$ , comme cela n'arrive que dans au plus 5 % de ces échantillons, on rejettera l'hypothèse faite sur  $p$ , avec un risque de se tromper de 5 %.



On en déduit la propriété suivante :

**Propriété** On considère une population dans laquelle on **suppose** que la proportion d'un caractère est  $p$ . Après expérience, on **observe** la fréquence  $f$  de ce caractère dans un échantillon aléatoire de taille  $n$ .

Soit l'hypothèse : « La proportion de ce caractère dans la population est  $p$ . »

Soit  $I$  l'intervalle de fluctuation de la fréquence à 95 % dans les échantillons de taille  $n$ .

Si  $f \notin I$  : on rejette cette hypothèse au seuil de risque 5 %.

Sinon, on ne rejette pas cette hypothèse au seuil de risque 5 % ; on l'accepte.

Retour à la problématique : Le pièce est elle alors truquée ?

.....

.....

.....

Ex : 2, 4 p92 ; 6, 7, 8, 10, 11 p93

### III- Intervalle de fluctuation d'une moyenne.

On dispose d'une population sur laquelle est définie une variable aléatoire  $X$  dont on connaît l'espérance (ou la moyenne)  $\mu$  et l'écart type  $\sigma$ .


On s'intéresse aux échantillons de taille  $n$ . Auront-ils tous la même moyenne ?

Non, certains peuvent être constitués d'éléments atypiques et

avoir une moyenne très différente de celle de la population (surtout si l'échantillon est de petite taille).

Pour prélever les échantillons de taille  $n$ , on a procédé à  $n$  épreuves indépendantes de variables aléatoires  $X_1, X_2, \dots, X_n$  de même loi que  $X$ .

La variable aléatoire  $\bar{X}_n = \frac{X_1 + X_2 + \dots + X_n}{n}$  associe à tout échantillon de taille  $n$  sa moyenne.



#### **Théorème de la limite centrée :**

Contexte : La variable aléatoire  $X$  suit une loi quelconque sur la population avec  $E(X) = \mu$  et  $\sigma(X) = \sigma$ .

On prélève, au hasard, un échantillon de taille  $n$ , avec  $n > 30$ , de moyenne  $\bar{X}_n$ .

Alors la variable aléatoire  $\bar{X}_n$  suit approximativement la loi normale  $N(\mu ; \frac{\sigma}{\sqrt{n}})$

**Exemple 1 :** Une machine fabrique des pièces en grande série. A chaque pièce tirée au hasard, on associe sa longueur exprimée en millimètres ; on définit ainsi une variable aléatoire  $X$ .

On suppose que  $X$  suit la loi normale  $N(28,20 ; 0,027)$

Soit  $M_n$  la variable aléatoire qui à tout échantillon de taille  $n$  associe la moyenne des longueurs des  $n$  pièces de l'échantillon.

Le résultat précédent nous dit que pour  $n$  assez grand :

$M_n$  suit la loi normale  $N(\dots\dots\dots ; \dots\dots\dots)$

Supposons que les échantillons soient de taille 100, alors,  $M_{100}$  suit la loi normale  $N(\dots\dots\dots ; \dots\dots\dots)$

**Exemple 2 :** Les statistiques des notes obtenues en mathématiques au bac STI en France pour l'année 2006 sont :

Moyenne nationale :  $\mu = 10,44$

Ecart type :  $\sigma = 1,46$

Une classe de BTS comporte 35 élèves en 2006/2007 issus d'un bac STI en 2006.

Calculer la probabilité que la moyenne de cette classe soit supérieure à 10.

**Propriété :** L'intervalle de fluctuation de  $m_e$  au seuil  $1-\alpha$  est donné par :

$I = [m - u_\alpha \frac{\sigma}{\sqrt{n}} ; m + u_\alpha \frac{\sigma}{\sqrt{n}}]$ , avec  $u_\alpha$  l'unique réel tel que  $P(-u_\alpha \leq Z \leq u_\alpha) = 1-\alpha$  où  $Z$  suit une loi normale  $N(0;1)$ .

Ex : 12, 14, 15 p94