

Statistique inférentielle

Objectifs du chapitre

- **Savoir estimer** ponctuellement une proportion, une moyenne ou un écart type d'une population à l'aide de la calculatrice ou d'un logiciel à partir d'un échantillon.
- **Savoir déterminer** un intervalle de confiance à un niveau de confiance souhaité pour une proportion ou une moyenne et l'exploiter.
- **Savoir déterminer** la taille nécessaire d'un échantillon pour estimer une proportion ou une moyenne avec une précision donnée.
- **Savoir utiliser** les tests bilatéraux et unilatéraux relatifs à une proportion ou à une moyenne ainsi qu'à la comparaison de deux proportions ou de deux moyennes.
- **Savoir analyser** les risques d'erreurs de première et seconde espèces associés à la prise de décision.
- **Traiter** d'autres exemples de procédures comme le test du khi-deux.

Pour reprendre contact

Dans chaque cas, indiquer la bonne réponse.

	Questions	Réponse A	Réponse B	Réponse C
1	La moyenne m et la variance v de la série statistique $\{1,2,3,5,4,1,2,4,5,6,6\}$ sont égales à :	$m = 3,55$ et $v = 3,47$	$m = 3,55$ et $v = 3,16$	$m = 3,55$ et $v = 1,78$
2	Soit X une variable aléatoire suivant la loi normale $\mathcal{N}(\mu ; \sigma)$, alors $P(\mu - \sigma \leq X \leq \mu + \sigma)$ est de :	50 %	68 %	95 %
3	Soit X une variable aléatoire suivant la loi normale $\mathcal{N}(20 ; 5)$, alors la valeur h telle que $P(X \leq h) = 0,95$ est de :	28,22	55,44	20
4	Soit $(X_i)_{1 \leq i \leq n}$ n variables aléatoires indépendantes, de même loi de probabilité, d'espérance μ et d'écart type σ , alors pour n suffisamment grand, la variable aléatoire $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ suit :	la loi binomiale de paramètres $(\mu ; \sigma)$.	la loi normale de paramètres $(\mu ; \sigma)$.	la loi normale de paramètres $\left(\mu ; \frac{\sigma}{\sqrt{n}}\right)$.

Activité 1 Pour faire connaissance

Partie A – Loi des grands nombres

1 On lance un dé bien équilibré et on considère la variable aléatoire X qui prend pour valeur le résultat du dé.

a. Donner sous forme de tableau la loi de probabilité de X .

b. En déduire l'espérance μ et la variance théorique σ^2 .


2 On lance p fois ce dé bien équilibré pour obtenir une liste $\{x_1, x_2, \dots, x_p\}$ de p résultats. On appelle $\bar{X}_p$ la variable aléatoire associant la moyenne

de cette liste et $V_p = \sum_{i=1}^n \frac{(x_i - \bar{X}_p)^2}{n}$ sa variance.

a. À l'aide de GeoGebra créer un curseur p variant de 1 à 5 000.

b. Dans la ligne de saisie, à l'aide de l'instruction **Séquence** et de l'instruction **AléaEntreBornes**, créer une liste ℓ de p nombres aléatoires entre 1 et 6.

c. Créer les points M de coordonnées $(p; \text{Moyenne}[\ell])$ et V de coordonnées $(p; \text{Variance}[\ell])$.



Que constate-t-on pour des grandes valeurs de p ?

Partie B – Estimation

On cherche à estimer l'espérance μ et la variance théorique σ^2 à l'aide d'un échantillon de 30 lancers. Il semble que la moyenne et la variance de cet échantillon soient un bon estimateur. Mais dans quelle mesure ces estimations sont-elles satisfaisantes ?

1 Pour estimer l'espérance, on regarde la répartition des moyennes de 100 échantillons de 30 lancers d'un dé bien équilibré autour de l'espérance $\mu = 3,5$.

a. Sous GeoGebra, à l'aide des instructions vues dans la partie A, insérer un bouton qui à chaque clic crée une liste nommée « moyenne » contenant les 100 moyennes de 100 échantillons de 30 nombres entiers tirés aléatoirement entre 1 et 6.

b. Taper dans la ligne de saisie l'instruction : **Séquence**((k,Elément[moyenne,k]),k,1,100).


i. Que fait cette instruction ?

ii. Représenter la droite d'équation $y = 3,5$.

iii. À l'issue de plusieurs clics, les moyennes semblent-elles équitablement réparties autour de l'espérance ?

iv. Pour vérifier ce résultat, afficher la moyenne de ces 100 moyennes. Confirme-t-on la réponse précédente ?

c. Soit $(X_i)_{1 \leq i \leq n}$ n variables aléatoires indépendantes suivant la même loi de probabilité d'espérance μ . On pose $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$. Montrer que l'espérance $E(\bar{X}) = \mu$.




La moyenne d'un échantillon est **une estimation ponctuelle sans biais** de l'espérance dans le sens où sa fluctuation sur différents échantillons est « centrée » sur l'espérance.

De manière plus précise, l'espérance de la variable aléatoire $\bar{X}$ est égale à l'espérance μ de la loi de probabilité suivie par les variables aléatoires indépendantes (X_i) .

2 On regarde maintenant la répartition des variances de 100 échantillons de 30 lancers d'un dé bien équilibré autour de la variance théorique $\sigma^2 = \frac{35}{12} \approx 2,92$.

a. Sous GeoGebra, reprendre l'activité précédente pour estimer la répartition de 100 variances autour de σ .

b. En affichant la moyenne de ces 100 variances et à l'issue de plusieurs clics, peut-on affirmer que la variance de la série statistique de 30 lancers d'un dé est un bon estimateur de la variance théorique ?



c. On remarque que la moyenne de nos 100 variances est toujours en deçà de notre variance théorique. La variance d'un échantillon est **une estimation ponctuelle avec biais** de la variance théorique dans le sens où sa fluctuation sur les différents échantillons n'est pas exactement « centrée » sur la variance théorique.

De manière plus précise, soit $(X_i)_{1 \leq i \leq n}$ n variables aléatoires indépendantes suivant la même loi de probabilité d'espérance μ et de variance théorique σ^2 .

On pose $V_n = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ la variable aléatoire qui à un échantillon de taille n associe sa variance. On montre que $E(V_n) = \frac{n-1}{n} \sigma^2$ ce qui fait de V_n un estimateur biaisé.

Montrer que $V_{n-1} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ est un estimateur sans biais de σ^2 .


d. La commande *GeoGebra* **VarianceEchantillon** donne l'estimateur sans biais d'une variance à partir d'une liste statistique résumant un échantillon. Corriger l'activité sur la variance (le script du bouton créé) et vérifier en effectuant quelques tirages de 100 variances.

Activité 2



Intervalle de confiance et incertitude de mesures

On souhaite trouver de manière expérimentale la valeur μ d'un caractère physique. Pour ce faire, on effectue une série de 50 mesures (x_i) de manière indépendante et dans les mêmes conditions expérimentales, série représentée par l'histogramme des effectifs ci-dessous.



On admet que ces mesures, de moyenne m , suivent une loi de probabilité d'espérance μ , la valeur recherchée du caractère physique, et d'écart type σ . Soit $\bar{X}$ la variable aléatoire qui, à un échantillon de 50 mesures, associe la moyenne de ces mesures.

1 Quelle loi de probabilité suit $\bar{X}$?

2 En déduire la probabilité pour que μ appartienne à l'intervalle $\left[\bar{X} - 1,96 \frac{\sigma}{\sqrt{50}}; \bar{X} + 1,96 \frac{\sigma}{\sqrt{50}} \right]$.


3 L'intervalle $\left[m - 1,96 \frac{\sigma}{\sqrt{50}}; m + 1,96 \frac{\sigma}{\sqrt{50}} \right]$ est appelé intervalle de confiance de μ de coefficient de confiance 95 % (ou avec le risque 5 %).

a. À l'aide des données fournies par l'histogramme de l'échantillon, déterminer sa moyenne m et une estimation ponctuelle de l'écart type σ .

b. En déduire un intervalle de confiance de risque 5 % de la valeur μ du caractère physique.

4 La théorie physique sous-jacente au calcul de μ montre que théoriquement $\mu = 52,5$. On a représenté

ci-dessous de manière verticale 50 intervalles de confiance au risque 5 % de la valeur μ .



a. L'expérience semble-t-elle confirmer la théorie ?

b. En traçant la droite d'équation $y = 52,5$, de quelle manière est répartie μ dans les différents intervalles ?

5 Application : dans la fabrication de comprimés effervescents, il est prévu que chaque comprimé contienne 1 625 mg de bicarbonate de sodium (NaHCO_3). Afin de contrôler la fabrication de ces médicaments, on a prélevé un échantillon de 150 comprimés et on a mesuré la quantité de NaHCO_3 pour chacun d'eux. Les résultats obtenus sont résumés dans le tableau suivant :

Classes	[1 610 ; 1 615[	[1 615 ; 1 620[	[1 620 ; 1 625[
Effectif	7	8	42

Classes	[1 625 ; 1 630[	[1 630 ; 1 635[
Effectif	75	18

a. À partir des résultats obtenus pour cet échantillon, assimilé à un échantillon non exhaustif, et en convenant que les valeurs mesurées sont regroupées au centre de chaque classe, donner à 10^{-2} près les estimations ponctuelles $\bar{x}$ et s respectives de la moyenne μ et de l'écart type σ , de la quantité de NaHCO_3 dans la population.

b. On prendra ici pour valeur de σ son estimation ponctuelle s . On appelle $\bar{X}$ la variable aléatoire qui, à tout échantillon de taille $n = 150$, associe la quantité moyenne de NaHCO_3 de cet échantillon. Déterminer un intervalle de confiance de la quantité moyenne de NaHCO_3 dans la population avec le coefficient de confiance 95 %.

1. Estimation ponctuelle et intervalle de confiance

Étant donné une population sur laquelle on étudie un caractère de moyenne μ et d'écart type σ inconnus, pour tout échantillon non exhaustif de taille n assez grand ($n \geq 30$) prélevé au hasard, on choisit :

- la moyenne $\bar{x}$ sur l'échantillon comme estimation ponctuelle de la moyenne inconnue μ ;
- le nombre $\sqrt{\frac{n}{n-1}} \sigma'$ où σ' est l'écart type de l'échantillon comme estimation ponctuelle de l'écart type inconnu σ ;
- dans le cas où le caractère étudié est de proportion inconnue p sur la population, on choisit la **fréquence** f sur l'échantillon comme **estimation ponctuelle de la proportion** inconnue p .

A INTERVALLE DE CONFIANCE D'UNE MOYENNE

On considère une population dont le caractère étudié a une moyenne μ inconnue et un écart type σ connu.

Une probabilité α choisie à l'avance permet de définir un réel positif t tel que : $P(-t \leq Y \leq t) = 1 - \alpha$ où Y suit la loi normale $\mathcal{N}(0; 1)$.

$1 - \alpha$	0,99	0,98	0,95	0,90
t	2,58	2,33	1,96	1,645

Soit $\bar{x}$ la moyenne d'un échantillon de taille n de la population.

L'intervalle $\left[\bar{x} - t \frac{\sigma}{\sqrt{n}} ; \bar{x} + t \frac{\sigma}{\sqrt{n}} \right]$ est appelé **intervalle de confiance de la moyenne** μ de la population avec le **coefficient de confiance** $1 - \alpha$ (ou de **risque** α). Il a pour centre la moyenne $\bar{x}$ de l'échantillon considéré.

i Lorsque l'effectif n de l'échantillon est suffisamment grand ($n \geq 30$) et que l'écart type σ est inconnu, on prend pour valeur de s son estimateur ponctuel issu de l'échantillon.

B INTERVALLE DE CONFIANCE D'UNE PROPORTION

On considère une population dont le caractère étudié est de proportion inconnue p . Lorsque p « n'est pas trop proche de 0 ou de 1 », la variable aléatoire $\bar{X}$ qui, à chaque échantillon non exhaustif de taille $n \geq 30$, associe la fréquence f du caractère étudié suit la loi normale

$$\mathcal{N}\left(p; \sqrt{\frac{p(1-p)}{n}}\right).$$

On prend pour valeur de p son estimateur ponctuel f , pour valeur de l'écart type l'estimation ponctuelle $\sqrt{\frac{n}{n-1}} \sqrt{\frac{f(1-f)}{n}} = \sqrt{\frac{f(1-f)}{n-1}}$ et on garde le même raisonnement et les mêmes notations que précédemment :

l'intervalle $\left[f - t \sqrt{\frac{f(1-f)}{n-1}} ; f + t \sqrt{\frac{f(1-f)}{n-1}} \right]$ est appelé **intervalle de confiance de la fréquence** p de la population avec le **coefficient de confiance** $1 - \alpha$ (ou de **risque** α). Il a pour centre la fréquence f de l'échantillon.

Certains prennent comme estimation ponctuelle de l'écart type le nombre $\sqrt{\frac{f(1-f)}{n}}$. Cela change peu pour des valeurs de n assez grandes.

2. Tests de validité d'hypothèse

A TEST BILATÉRAL RELATIF À UNE MOYENNE

On cherche à tester si la moyenne μ inconnue d'une population sur laquelle on étudie un caractère est égale ou non à une valeur A . On suppose que l'écart type σ est connu.

On émet alors deux hypothèses :

- l'hypothèse nulle $H_0 : \mu = A$,
- et l'hypothèse alternative $H_1 : \mu \neq A$.

On désigne ainsi deux types d'erreurs :

- l'erreur de première espèce, « on rejette une hypothèse vraie » ;
- l'erreur de seconde espèce, « on accepte une hypothèse fausse ».

Sous l'hypothèse H_0 , pour n assez grand ($n \geq 30$), la variable aléatoire $\bar{X}$ qui à chaque échantillon non exhaustif de taille n associe sa moyenne $\bar{x}$ suit la loi normale $\mathcal{N}\left(A; \frac{\sigma}{\sqrt{n}}\right)$.

On fixe un seuil α et on détermine le réel h tel que $P(A-h \leq \bar{X} \leq A+h) = 1-\alpha$.


i En posant $h = t \frac{\sigma}{\sqrt{n}}$, on obtient pour $\alpha = 0,05$, $t = 1,96$ et pour $\alpha = 0,01$, $t = 2,58$.

On prélève alors un échantillon, on détermine sa moyenne $\bar{x}$ et on applique la règle de décision suivante :

- si $\bar{x}$ n'appartient pas à l'intervalle $[A-h; A+h]$, on rejette l'hypothèse H_0 au seuil α qui correspond à la probabilité (au risque) de commettre une erreur de première espèce, $\alpha = P(\text{refuser } H_0 | H_0 \text{ vraie})$;
- si $\bar{x}$ appartient à l'intervalle $[A-h; A+h]$, on accepte l'hypothèse H_0 au niveau de confiance $1-\alpha$, mais ce faisant on court le risque β d'erreur de seconde espèce, $\beta = P(\text{accepter } H_0 | H_1 \text{ vraie})$.

i Pour déterminer le risque β , il faut connaître la loi de probabilité que suit $\bar{X}$ sous l'hypothèse H_1 .

Le réel $1-\beta$ est la probabilité de rejeter H_0 sachant que H_1 est vraie : c'est par définition la **puissance du test**.




Réalité \ Décision	H_0 vraie	H_1 vraie
Non rejet de H_0	Correct. Niveau de confiance $1-\alpha$	Manque de puissance. Risque β de seconde espèce
Rejet de H_0	Rejet à tort. Risque α de première espèce	Puissance du test $1-\beta$

La plupart du temps, les erreurs des deux types n'ont pas la même importance de sorte que l'on essaie de limiter la plus grave.

B TEST UNILATÉRAL (À GAUCHE) RELATIF À UNE MOYENNE

Dans le même cadre que précédemment, on cherche à tester si la moyenne inconnue μ est inférieure à une valeur A . On émet alors les deux hypothèses suivantes : l'hypothèse nulle $H_0 : \mu = A$ et l'hypothèse alternative $H_1 : \mu \leq A$.

On se place toujours sous l'hypothèse H_0 . On fixe un seuil α et on détermine le réel h tel que : $P(A-h \leq \bar{X}) = 1-\alpha$.



i En posant $h = t \frac{\sigma}{\sqrt{n}}$, on obtient pour $\alpha = 0,05$, $t = -1,645$ et pour $\alpha = 0,01$, $t = -2,33$. Les valeurs ne sont pas les mêmes que précédemment, la région critique n'étant située que d'un seul côté.

La prise de décision, avec les mêmes risques, est la même que précédemment avec l'intervalle $[A-h; +\infty[$.

On obtient de la même manière un **test unilatéral à droite** en posant comme hypothèse $H_1 : \mu \geq A$, la prise de décision s'effectuant sur l'intervalle $]-\infty; A+h]$.

i Lorsque la taille de l'échantillon est suffisante ($n \geq 30$) et que l'écart type est inconnu, on remplace souvent ce dernier par son estimation ponctuelle $\sqrt{\frac{n}{n-1}} \sigma'$ où σ' est l'écart type de l'échantillon.

C TESTS RELATIFS À UNE PROPORTION

Les tests précédents s'appliquent aussi à la proportion p du caractère d'une population dont on cherche à savoir si elle est égale ou non à A .

On émet alors deux hypothèses :

- l'hypothèse nulle $H_0, p = A$,
- et l'hypothèse alternative $H_1 (p \neq A, \text{test bilatéral ; ou } p > A \text{ ou } p < A, \text{test unilatéral})$.

Sous l'hypothèse H_0 , la variable aléatoire X qui à chaque échantillon de taille n associe l'effectif s du caractère étudié suit alors la loi binomiale $\mathcal{B}(n; A)$.

On fixe un seuil α et on détermine le réel h tel que $P(nA - h \leq X \leq nA + h) = 1 - \alpha$ (dans le cas de $H_1, p \neq A$).

On applique alors les règles de décision précédentes suivant que l'effectif s appartient ou non à l'intervalle $[nA - h; nA + h]$.

Quand les conditions sont réunies pour que la loi binomiale soit approximable par une loi normale ($n \geq 30$ et « p pas trop petit » de manière à avoir $np \geq 15$ et $n(1-p) \geq 15$) sous l'hypothèse H_0 , les

fréquences d'échantillons de taille n suivent la loi $\mathcal{N}\left(A; \sqrt{\frac{A(1-A)}{n}}\right)$.

On fixe alors un seuil α et on applique les règles de décision précédentes sur la fréquence f d'un échantillon prélevé au hasard dans la population.

D COMPARAISON DE DEUX ÉCHANTILLONS

On dispose de deux échantillons A et B d'effectifs respectifs n_A et n_B , de moyennes $\bar{x}_A$ et $\bar{x}_B$ et d'écart type σ'_A et σ'_B . On cherche à savoir s'ils ont été prélevés dans la même population.

Pour ce faire, on détermine l'écart type ponctuel $\sigma_A = \sqrt{\frac{n_A}{n_A - 1}} \sigma'_A$ de la population P_A associée à A et

l'écart type ponctuel $\sigma_B = \sqrt{\frac{n_B}{n_B - 1}} \sigma'_B$ de la population P_B associée à B.

La variable aléatoire $\bar{X}_A$ (respectivement $\bar{X}_B$) qui à tout échantillon de taille n_A (respectivement n_B)

de la population P_A (respectivement P_B) associe sa moyenne suit la loi normale $\mathcal{N}\left(\mu_A; \frac{\sigma_A}{\sqrt{n_A}}\right)$ (respectivement $\mathcal{N}\left(\mu_B; \frac{\sigma_B}{\sqrt{n_B}}\right)$).

En supposant $\bar{X}_A$ et $\bar{X}_B$ indépendantes, on considère alors la variable $D = \bar{X}_A - \bar{X}_B$.

De par les propriétés de l'espérance et de la variance de la somme de deux variables aléatoires indépendantes, D suit la loi normale $\mathcal{N}\left(\mu_A - \mu_B; \sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}\right)$.

On choisit $H_0, \mu_A = \mu_B$, comme hypothèse nulle et une hypothèse alternative $H_1 (\mu_A \neq \mu_B \text{ ou } \mu_A \geq \mu_B \text{ ou encore } \mu_A \leq \mu_B)$.

Sous l'hypothèse H_0 , D suit la loi normale $\mathcal{N}\left(0; \sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}\right)$.

On fixe un seuil α et on détermine h tel que $P(-h \leq D \leq h) = 1 - \alpha$ (dans le cas où $H_1 : \mu_A \neq \mu_B$).

La règle de décision est la même que précédemment suivant que $\bar{D} = \bar{X}_A - \bar{X}_B$ appartient à l'intervalle $[-h; h]$ ou pas.

Exercices résolus



A Exploiter un intervalle de confiance relatif à une proportion et déterminer la taille d'un échantillon sous une contrainte donnée

Un candidat à une élection fait effectuer un sondage dans sa circonscription comportant un grand nombre d'électeurs : sur un échantillon (assimilé à un échantillon non exhaustif) de 2 485 personnes interrogées au hasard, 51,1 % déclarent vouloir voter pour ce candidat.

Soit F la variable aléatoire qui, à tout échantillon de taille $n = 2\,485$ prélevé au hasard et avec remise dans cette population, associe le pourcentage d'électeurs de cet échantillon voulant voter pour le candidat. On note p le pourcentage inconnu des électeurs de la circonscription voulant voter pour le candidat.

1. Quelle loi de probabilité la variable aléatoire F suit-elle ?
2. Donner une estimation ponctuelle de p ainsi que de l'écart type et déterminer un intervalle de confiance au risque de 5 %.
3. Au vu du résultat de ce sondage, le candidat a-t-il raison de penser que, si l'élection avait lieu au moment où le sondage a été réalisé et si les réponses au sondage étaient sincères, il aurait été élu au premier tour ?
4. Quel nombre minimal n de personnes doit comporter l'échantillon pour qu'avec 51,1 % d'intentions de vote pour le candidat dans cet échantillon, l'intervalle de confiance de p au risque de 5 % ne comporte que des pourcentages supérieurs à 50 % ?
5. Reprendre la question précédente au risque de 1 %.

RÉSOLUTION

1. F suit la loi normale $\mathcal{N}\left(p; \sqrt{\frac{p(1-p)}{2\,485}}\right)$.

2. Une estimation ponctuelle de p est 0,511 et celle de l'écart type est $\sqrt{\frac{0,511(1-0,511)}{2\,485-1}}$.

Au risque de 5 %, soit avec un coefficient de confiance de 95 %, l'intervalle de confiance est :

$$\left[0,511 - 1,96\sqrt{\frac{0,511(1-0,511)}{2\,485-1}}; 0,511 + 1,96\sqrt{\frac{0,511(1-0,511)}{2\,485-1}}\right], \text{ soit } [0,491; 0,531].$$

3. Avec un coefficient de confiance de 95 %, le pourcentage p des électeurs de la circonscription votant pour le candidat est situé dans l'intervalle $[49,1\%; 53,1\%]$. Il peut très bien être égal à 49,5 % et auquel cas le candidat n'est pas élu.

4. Au risque de 5 %, l'intervalle de confiance est :

$$\left[0,511 - 1,96\sqrt{\frac{0,511(1-0,511)}{n-1}}; 0,511 + 1,96\sqrt{\frac{0,511(1-0,511)}{n-1}}\right].$$

On cherche donc n tel que $0,511 - 1,96\sqrt{\frac{0,511(1-0,511)}{n-1}} \geq 0,5$, soit $n \geq \frac{1,96^2}{0,011^2} \times 0,511 \times 0,489 + 1$.

Le nombre minimal de personnes sondées est donc de 7 935.

5. Au risque de 1 %, l'intervalle de confiance est :

$$\left[0,511 - 2,58\sqrt{\frac{0,511(1-0,511)}{n-1}}; 0,511 + 2,58\sqrt{\frac{0,511(1-0,511)}{n-1}}\right].$$

En raisonnant comme précédemment, on trouve un nombre minimal n de 13 748 électeurs. Pour diminuer le risque d'erreur, il faut un plus grand échantillon.



B Construire un test bilatéral relatif à une moyenne

Une machine fabrique des barres en grande série. On veut vérifier le bon réglage de la machine.

On appelle L la variable aléatoire qui prend pour valeur la longueur d'une barre. On admet que L suit une loi normale de moyenne μ et d'écart type 1.

Dans le cas où la machine est bien réglée, la moyenne μ est égale à 1 000.

On appelle $\bar{L}$ la variable aléatoire qui prend pour valeur la moyenne des longueurs des 100 barres d'un échantillon aléatoire.

Exercices résolus

1. On construit un test d'hypothèse bilatéral permettant de vérifier le bon réglage de la machine au seuil de 2 %.

a. Donner l'hypothèse nulle H_0 et l'hypothèse alternative H_1 .

b. Sous l'hypothèse H_0 , quelle est la loi de $\bar{L}$?

c. Déterminer la région critique et énoncer la règle de décision relative à ce test.

2. On a regroupé par classes les longueurs des barres d'un échantillon :

Longueur	[997 ; 999[	[999 ; 1 001[	[1 001 ; 1 003[
Quantité	14	75	11

a. Déterminer une valeur approchée de la moyenne $\bar{l}$ de la longueur des barres prélevées, en supposant que dans chaque classe tous les éléments sont situés au centre.

b. Au vu de cet échantillon, que peut-on conclure quant au réglage de la machine ?

RÉSOLUTION

1. a. $H_0 : \mu = 1\,000$. Le test étant bilatéral, on choisit comme hypothèse alternative $H_1 : \mu \neq 1\,000$.

b. Sous l'hypothèse H_0 , $\bar{L}$ suit la loi normale $\mathcal{N}\left(1\,000; \frac{1}{\sqrt{100}}\right)$.

c. On cherche h tel que $P(1\,000 - h \leq \bar{L} \leq 1\,000 + h) = 1 - 0,02$. Soit, par symétrie, on recherche h tel que $P(\bar{L} \leq 1\,000 - h) = 0,01$. La calculatrice donne : $1\,000 - h = 999,767$.

On en déduit : $1\,000 + h = 1\,000,233$. La région critique est à l'extérieur de l'intervalle $[999,767 ; 1\,000,233]$.

On énonce ainsi la règle de décision :

On prélève au hasard un échantillon de 100 barres dont on calcule la moyenne $\bar{l}$ des longueurs.

Si $\bar{l}$ appartient à l'intervalle $[999,767 ; 1\,000,233]$, on accepte H_0 au seuil de 2 %.

Sinon, on refuse H_0 et on accepte H_1 au même seuil.

2. a. $\bar{l} = 999,94$ qui appartient à l'intervalle d'acceptation de H_0 .

b. On conclut au seuil de 2 % que la machine est bien réglée.



Construire un test bilatéral relatif à une proportion et mesurer les risques d'erreurs

On cherche à savoir si une pièce est truquée. Pour ce faire, on jette 100 fois la pièce et on note X la variable aléatoire comptant le nombre de fois où pile est obtenu.

On adopte la règle de décision suivante :

H_0 : la pièce n'est pas truquée et elle est acceptée si $X \in [40 ; 60]$; elle est refusée si $X \notin [40 ; 60]$.

1. Déterminer le risque α d'erreur de première espèce.

2. Dans le cas où la pièce est truquée avec une probabilité d'obtenir pile égale à 0,6 (respectivement 0,7), déterminer le risque β d'erreur de seconde espèce ainsi que la puissance du test.

RÉSOLUTION

1. X suit la loi binomiale $\mathcal{B}(100; 0,5)$ de sorte que $1 - \alpha = P(X \in [40 ; 60]) = 0,96$.

Ainsi le risque d'erreur de première espèce est de 4 %.

2. On pose comme hypothèse alternative H_1 : la pièce est truquée avec une probabilité égale à 0,6.

Par définition, $\beta = P(\text{accepter } H_0 | H_1 \text{ vraie})$. H_1 étant vraie, la variable aléatoire suit une loi binomiale $\mathcal{B}(100; 0,6)$ de sorte que $\beta = P(X \in [40 ; 60]) = 0,54$.

On a donc 54 % de chances de faire un risque d'erreur de seconde espèce (d'accepter que la pièce ne soit pas truquée alors qu'elle l'est), donc une puissance de test de $1 - \beta = 46$ %.

Pour une probabilité de 0,7, le risque tombe à 2 % et donc une puissance de test de 98 %. Ainsi, pour bien truquer sa pièce, mieux vaut que la probabilité d'obtenir pile ne soit pas trop voisine de 0,5.

1.1	Non enregistré
binomCdf(100,0.5,40,60)	0.9648
binomCdf(100,0.6,40,60)	0.537907
binomCdf(100,0.7,40,60)	0.020989

TP1



Comment évaluer des risques d'erreur ?

Un examen se présente sous la forme d'un QCM de 20 questions indépendantes. À chaque question, trois réponses sont proposées dont une seule est exacte. Un étudiant n'ayant fourni aucun travail répondra au hasard, donc correctement avec une probabilité $p = \frac{1}{3}$ à chaque question. L'objectif des professeurs est de recalcer ce type d'étudiant avec une probabilité d'environ 95 %. On peut considérer le QCM comme un test statistique devant permettre de détecter si l'étudiant qui le passe répond au hasard ; le QCM est alors un échantillon aléatoire non exhaustif de ses réponses.

A Construction d'un test

On construit un test d'hypothèse où l'hypothèse nulle correspond à un étudiant répondant au hasard et où l'hypothèse alternative correspond à un étudiant ayant travaillé.

1. Justifier que l'on teste l'hypothèse nulle $H_0 : p = \frac{1}{3}$ contre l'hypothèse alternative $H_1 : p > \frac{1}{3}$.

2. On suppose que H_0 est vraie et on désigne par X la variable aléatoire qui, à chaque étudiant de ce type, associe le nombre de ses bonnes réponses au QCM.

a. Quelle loi de probabilité suit X ?

b. À l'aide de la calculatrice, déterminer le plus petit nombre k tel que $P(X \leq k) \geq 95\%$.


3. On décide que lorsque le nombre de bonnes réponses est inférieur ou égal à k , on acceptera H_0 .

S'il est strictement supérieur à k , on supposera que l'étudiant a travaillé et l'on rejettera H_0 avec un risque α de rejet à tort (risque de première espèce).

a. Quel est le risque α ?

b. Sur le graphique ci-contre, indiquer la zone d'acceptation et la zone de rejet de H_0 .

c. Énoncer la règle de décision de l'examen.



B Utilisation du test et type d'erreur

On suppose qu'un étudiant sérieux et travailleur, mais mal assuré, a une probabilité $p = \frac{3}{5}$ de bien répondre à une question.

Le programme ci-après choisit de manière équiprobable une valeur de p parmi les deux valeurs $\frac{1}{3}$ et $\frac{3}{5}$.

Puis il simule le passage de l'examen et affiche la valeur de p choisie ainsi que le nombre r de bonnes réponses.

```

11 "test_qcm" enregistré
Define test_qcm()=
Prgm
  r=randInt(0,1)
  p=1/3 i+6/10 (1-i)
  r=randBin(20,p)
  Disp {p,r}
EndPrgm
    
```

1. Observer la fréquence des erreurs des première et seconde espèces en simulant 50 QCM.

2. On note β le risque d'erreur de seconde espèce, T l'événement « l'étudiant a travaillé », R l'événement « l'étudiant est reçu à l'examen », $\bar{T}$ et $\bar{R}$ leurs événements contraires.

Exprimer en fonction de α et β les probabilités suivantes : $P_T(R)$, $P_{\bar{T}}(R)$, $P_T(\bar{R})$ et $P_{\bar{T}}(\bar{R})$.

3. Un étudiant travailleur se manifeste alors : « Ce n'est pas juste ! Bien qu'ayant 60 % de chances de répondre correctement à chaque question, j'ai une chance sur quatre d'être recalé ! » Justifier son affirmation en calculant le risque β à l'aide des valeurs cumulées de la loi $\mathcal{B}\left(20; \frac{3}{5}\right)$.

4. En baissant la barre d'admission de 11 à 8, quel est dans ces conditions le risque β de seconde espèce ? Que devient alors le risque α de première espèce ?

C Puissance du test

Afin de diminuer β sans augmenter α , les professeurs décident de proposer un QCM de 100 questions.

On se place sous les mêmes hypothèses et notations qu'en A.

Soit $F = \frac{X}{100}$ la variable aléatoire correspondant aux fréquences des bonnes réponses.

1. Justifier que sous l'hypothèse H_0 la loi de F peut être approchée par une loi normale dont on précisera les paramètres.

2. Déterminer le réel h tel que $P(F \leq h) = 0,95$ et énoncer la règle de décision.

3. En modifiant le programme précédent, observer la fréquence des erreurs de première et seconde espèces en simulant 100 QCM de 100 questions.

4. On se place du point de vue de l'étudiant pour lequel $p = p_0$. Il se préoccupe de sa probabilité d'être reçu qui est $1 - \beta = P(F > 0,41 | p = p_0)$.

a. Compléter le tableau de valeurs ci-dessous :

p_0	0	0,1	0,2	0,3	0,4	0,5	0,6	0,7	0,8	0,9	1
$1 - \beta$											

b. Représenter graphiquement la fonction qui à p_0 associe la puissance du test $1 - \beta$.

Est-ce raisonnable ?

TP2



Comment construire un test du khi-deux ?

Soit une variable aléatoire discrète ou discrétisée, c'est-à-dire divisée en k classes de probabilités $p_1, \dots, p_k$. Soit un échantillon de taille n de cette variable aléatoire, fournissant pour chaque classe des effectifs $x_1, \dots, x_k$. Il s'agit de comparer ces effectifs aux valeurs théoriques :

Classes	Effectifs observés	Effectifs théoriques
1	x_1	$t_1 = np_1$
...	...	...
k	x_k	$t_k = np_k$

Il faut décider d'un critère d'adéquation des observations par rapport au modèle théorique.

De façon classique, on choisira l'écart quadratique réduit, noté χ^2_{obs} et valant : $\chi^2_{\text{obs}} = \sum_{i=1}^k \frac{(x_i - t_i)^2}{t_i}$.

Pour étudier la variabilité de ce critère, on introduit la variable aléatoire $T = \sum_{i=1}^k \frac{(X_i - np_i)^2}{np_i}$ où X_i est la variable aléatoire correspondant à l'effectif de la $i^{\text{ème}}$ classe. En particulier $\sum_{i=1}^k X_i = n$.

Alors, pour n grand, T suit une loi appelée **loi du khi-deux à $k - 1$ degrés de liberté**.

La calculatrice fournit la probabilité $P(T > t)$ ou encore renvoie la valeur de t telle que $P(T < t) = p$.

→ Construction

On choisit pour hypothèse nulle H_0 : « la probabilité que X appartienne à la classe i est égale à p_i » et pour hypothèse alternative H_1 : « il existe i tel que la probabilité précédente diffère de p_i ».

Si H_0 est vraie, alors la variable aléatoire T suit approximativement la loi du χ^2 à $k - 1$ degrés de liberté.

On construit un test unilatéral à droite en choisissant un seuil α et en déterminant t tel que $P(T > t) = \alpha$.

D'où la zone d'acceptation de H_0 au seuil α : $[0 ; t]$.

i La loi de T n'est qu'approchée et on donne la condition $np_i > 5$ pour l'effectif de chaque classe (sinon on regroupe les classes à effectif trop faible). C'est pour vérifier cette condition que l'on pratique le test du khi-deux sur les effectifs et non sur les fréquences.

→ Application

Un chercheur s'intéresse aux facteurs qui déterminent le choix des cours des étudiants. Il pose la question suivante à un échantillon de 50 étudiants : « Parmi les quatre facteurs suivants, lequel est le plus important lorsque vous sélectionnez un cours ? »

Les étudiants doivent choisir une des quatre propositions :

- l'intérêt pour le contenu du cours,
- le degré de complexité de l'examen,
- le professeur,
- l'heure à laquelle le cours se donne.

Voici les résultats obtenus :

	Contenu du cours	Examen	Professeur	Horaire
Pourcentage	36 %	34 %	14 %	16 %

Sur la base de ces données, le chercheur veut trouver si un facteur (ou plusieurs facteurs) est (sont) plus important(s) que les autres. Il teste à un niveau de signification $\alpha = 0,05$.

1. Quelle est l'hypothèse nulle ?
2. Compléter le tableau suivant :

	Contenu du cours	Examen	Professeur	Horaire
Effectif observé				
Effectif attendu				

3. Calculer la valeur de χ^2_{obs} .
4. Quel est le nombre de degrés de liberté ?
5. À l'aide de la calculatrice, déterminer la valeur de χ^2 théorique au niveau de signification 0,05 (c'est-à-dire le réel t tel que $P(X > t) = 0,05$).
6. Conclure sur le rejet ou non de l'hypothèse H_0 .

→ En guise d'exercice

On veut étudier la liaison entre les caractères : « être fumeur » (plus de 20 cigarettes par jour, pendant 10 ans) et « avoir un cancer de la gorge », sur une population de 1 000 personnes, dont 500 sont atteintes d'un cancer de la gorge. Voici les résultats observés :

Observé	Cancer	Non cancer	Total
Fumeur	342	258	600
Non fumeur	158	242	400
Total	500	500	1 000

En posant comme hypothèse H_0 « les caractères « fumeur » et « cancer » sont indépendants », remplir le tableau des résultats attendus ci-dessous et construire un test d'indépendance du khi-deux pour établir la liaison entre ces deux caractères (et donc de rejeter H_0).

Attendu	Cancer	Non cancer	Total
Fumeur			600
Non fumeur			400
Total	500	500	1000

Pour s'entraîner → CORRIGÉS, p. 247

Intervalle de confiance

1 * On a contrôlé le dosage d'un produit A à la sortie de deux chaînes de fabrication de pots de peinture.

Deux échantillons de 100 pots ont été analysés ; l'un provient de la chaîne n° 1, l'autre de la chaîne n° 2.

Le tableau ci-contre donne la répartition de l'échantillon de la chaîne n° 1 en fonction de la masse de produit A exprimée en grammes.

m (en g)	Effectifs
[100 ; 102[	1
[102 ; 104[	3
[104 ; 106[	25
[106 ; 108[	32
[108 ; 110[	27
[110 ; 112[	6
[112 ; 114[	4
[114 ; 116[	2

On donne des valeurs approchées de la moyenne m_2 et de l'écart type s_2 de l'échantillon fabriqué par la chaîne n° 2 : $m_2 = 107$ et $s_2 = 2$ (en grammes).

Dans les questions 1 et 2, les valeurs seront arrondies au dixième le plus proche.

1. En prenant les centres des classes, calculer une valeur approchée de la moyenne m_1 et de l'écart type s_1 de l'échantillon issu de la chaîne n° 1.

2. En considérant les résultats obtenus dans la première question, donner les estimations ponctuelles :

- des quantités moyennes μ_1 et μ_2 de produit A pour les productions de ces deux chaînes,
- des écarts types σ_1 et σ_2 correspondants.

2 * Une société fabrique des poutrelles mécaniques.

On cherche à estimer le pourcentage p , inconnu, des poutrelles défectueuses de la production.

On prélève un échantillon de 100 poutrelles dans la production. On constate qu'il contient trois poutrelles défectueuses parmi les 100.

1. Donner, à partir de cet échantillon, une estimation ponctuelle f du pourcentage p .

2. Déterminer une estimation de p par un intervalle de confiance centré en f avec un coefficient de confiance égal à 90 %. Pour les bornes de cet intervalle, on donnera des valeurs approchées comportant deux décimales.

3 * On s'intéresse à la longueur de l'ensemble des pièces produites par une machine en une journée. Elles sont assemblées par lots de 50. Un lot pris au hasard est considéré comme un échantillon de la fabrication. Le tableau ci-contre décrit la distribution des longueurs des pièces de ce lot en millimètres.

Longueur des pièces	Nombre de pièces
[107 ; 108[	1
[108 ; 109[	6
[109 ; 110[	14
[110 ; 111[	20
[111 ; 112[	9

1. On suppose que la longueur d'une pièce est égale à la valeur centrale de la classe dans laquelle elle est répertoriée. Calculer la moyenne $\bar{x}$ des longueurs des pièces de l'échantillon, ainsi que son écart type s . On retiendra pour x et s leurs valeurs arrondies au centième.

2. Dédurre des résultats obtenus à la question précédente, une estimation ponctuelle μ de la moyenne et une estimation ponctuelle σ de l'écart type des longueurs des pièces de la fabrication.

3. Estimer par un intervalle de confiance la moyenne des longueurs des pièces de la fabrication avec le coefficient de confiance 0,9.

4 ** Un atelier produit en grande série des pièces cylindriques. On désigne par X la variable aléatoire associant, à chaque pièce tirée au hasard dans la production, son diamètre x , en millimètres. On suppose que X suit la loi normale de moyenne 12,50 et d'écart type 0,02.

On note $\bar{X}$ la variable aléatoire qui, à tout échantillon de n pièces pris au hasard et avec remise dans la production, associe la moyenne des diamètres des n pièces. On note P_n la probabilité que cette variable aléatoire $\bar{X}$ appartienne à l'intervalle $[12,495 ; 12,505]$.

On suppose n assez grand et on rappelle que, dans ce cas, $\bar{X}$ suit approximativement la loi normale de moyenne 12,50 et d'écart type $\frac{0,02}{\sqrt{n}}$.

En utilisant cette loi, déterminer la taille minimale n de l'échantillon pour que la probabilité P_n soit supérieure ou égale à 0,97.

Test de validité d'hypothèse

5 ** Les statistiques ont permis d'établir qu'en période de compétition, la probabilité pour un sportif pris au hasard d'être déclaré positif au contrôle antidopage est égale à 0,02. On décide de construire un test qui, à la suite des contrôles sur un échantillon de 50 sportifs prélevé au hasard, permette de décider si, au seuil de signification de 10 %, le pourcentage de sportifs contrôlés positifs est de $p = 0,02$.

1. Soit F la variable aléatoire qui, à tout échantillon aléatoire (supposé non exhaustif) de 50 sportifs contrôlés, associe le pourcentage de sportifs contrôlés positivement. On suppose que F suit la loi normale :

$$\mathcal{N}\left(p; \sqrt{\frac{p(1-p)}{n}}\right) \text{ où } p = 0,02 \text{ et } n = 50.$$

Énoncer une hypothèse nulle H_0 et une hypothèse alternative H_1 pour ce test bilatéral. Déterminer, sous l'hypothèse H_0 , le réel positif a tel que $P(p - a \leq F \leq p + a) = 0,9$. Énoncer la règle de décision du test.

2. Dans l'échantillon E deux contrôles antidopage ont été déclarés positifs. En appliquant la règle de décision du test à cet échantillon assimilé à un échantillon aléatoire non exhaustif, peut-on conclure au seuil de risque 10 % que l'échantillon observé est représentatif de l'ensemble de la population sportive ?

6 * Une machine fabrique des tiges en grande série. La production étant importante, on assimile tout prélèvement d'échantillon à un prélèvement avec remise.

La machine est supposée bien réglée quand la proportion de pièces acceptables est supérieure ou égale à 90 %. Pour contrôler le réglage de la machine, on construit un test permettant de décider si, au seuil de 5 %, la machine est bien réglée et on prélève de temps en temps des échantillons aléatoires de 150 tiges.

1. Soit F la variable aléatoire qui à tout échantillon aléatoire de 150 tiges associe le pourcentage de tiges acceptables dans cet échantillon.

On choisit pour hypothèse nulle $H_0 : p = 90 \%$, et pour hypothèse alternative $H_1 : p < 90 \%$.

Déterminer le nombre réel h tel que, sous l'hypothèse H_0 , $P(F > h) = 0,95$.

Énoncer la règle de décision de ce test.

2. On prélève un échantillon aléatoire de 150 tiges. On trouve 22 tiges défectueuses.

Quel est le pourcentage de tiges acceptables de cet échantillon ?

En appliquant la règle de décision du test à cet échantillon non exhaustif, peut-on conclure, au seuil de 5 %, que la machine est bien réglée ?

7 * On fabrique des pièces en série. Soit X la variable aléatoire qui, à toute pièce prise au hasard dans la production, associe sa cote exprimée en mm. On sait que X suit une loi normale d'écart type $\sigma = 2,4$ mm, mais on a des doutes sur l'espérance mathématique μ de X .

Afin de vérifier l'espérance mathématique de X , on prélève un échantillon de 50 pièces. On assimile tout échantillon de 50 pièces à un échantillon aléatoire non exhaustif. Le tableau suivant donne la distribution des mesures des cotes arrondies à l'entier le plus proche :

Cotes	147	148	149	150	151	152	153	154
Effectifs	2	3	5	10	9	9	8	4

1. Calculer la moyenne $\bar{x}$ de cet échantillon. On ne calculera pas son écart type.

2. On suppose que la variable aléatoire X qui à tout échantillon de 50 pièces prélevées au hasard associe la moyenne des cotes des pièces de cet échantillon suit la

loi normale $\mathcal{N}\left(\mu; \frac{2,4}{\sqrt{50}}\right)$.

On veut construire un test bilatéral pour permettre d'accepter ou de rejeter, au risque 5 %, l'hypothèse selon laquelle l'espérance mathématique μ de X est 150 mm.

On prend comme hypothèse nulle $H_0 : \mu = 150$, et comme hypothèse alternative $H_1 : \mu \neq 150$.

a. Trouver un réel positif h tel que, sous l'hypothèse H_0 : $P(150 - h \leq X \leq 150 + h) = 0,95$.

b. Énoncer la règle de décision.

c. Utiliser ce test avec l'échantillon des 50 pièces proposé dans cet énoncé et conclure.

Pour maîtriser

8 * → CORRIGÉS, p. 247 Dans un pays voisin, on doit bientôt élire le président de la République. Afin d'apprécier ses chances, le candidat A fait procéder à un sondage un mois avant la date du scrutin.

On tire au hasard 900 personnes dans l'ensemble de tous les électeurs (compte tenu du nombre total d'électeurs, le tirage peut être assimilé à un tirage avec remise).

Sur ces 900 personnes, 435 ont déclaré voter pour le candidat A.

1. Donner une estimation ponctuelle, à 10^{-2} près, de la proportion p d'électeurs favorables au candidat A.

2. On note X_n la variable aléatoire qui, à tout échantillon de n électeurs, associe la proportion p_n d'électeurs favorables à A.

On considère alors le sondage précédent. Donner, pour l'estimation de p , un intervalle de confiance avec le coefficient de confiance 95 %. Les bornes de cet intervalle seront données à 10^{-2} près.

3. Un organe de presse désire publier le résultat du sondage. Au vu des résultats précédents, la diffusion de l'intervalle de confiance peut-elle intéresser les lecteurs ? Pourquoi ?

9 * Une entreprise de matériel pour l'industrie produit des pièces circulaires qui servent à la fabrication de modules. Soit X la variable aléatoire qui, à tout échantillon de 60 pièces prélevées au hasard dans la production de la journée considérée, associe la moyenne des diamètres des pièces de cet échantillon.

La production est assez importante pour qu'on puisse assimiler tout prélèvement à un tirage avec remise.

On suppose que $\bar{X}$ suit la loi normale de moyenne μ et d'écart type $\frac{\sigma}{\sqrt{60}}$ avec $\sigma = 0,084$.

On mesure le diamètre, exprimé en centimètres, de chacune des 60 pièces d'un échantillon choisi au hasard et avec remise dans la production d'une journée. On constate que la valeur approchée arrondie à 10^{-3} près de la moyenne $\bar{x}$ de cet échantillon est $\bar{x} = 4,012$.

1. À partir des informations portant sur cet échantillon, donner une estimation ponctuelle à 10^{-3} près, de la moyenne μ du diamètre des pièces produites pendant cette journée.

2. Déterminer un intervalle de confiance centré en $\bar{x}$ de la moyenne μ des diamètres des pièces produites pendant la journée considérée, avec le coefficient de confiance 95 %.

3. On considère l'affirmation suivante : « la moyenne μ est obligatoirement entre 3,991 et 4,033 ». Peut-on déduire de ce qui précède qu'elle est vraie ?

10 ** Dans cet exercice, on étudie la charge de rupture d'un fil de « soie discontinue » stocké sur un enrouleur.

1. Pour cette question, les valeurs numériques seront arrondies au millièm.

On a fait un essai dynamométrique sur un fil de soie discontinue stocké sur un enrouleur.

Les 12 éprouvettes de fil testées sont prélevées au hasard sur la partie extérieure de l'enroulement.

On a obtenu les résultats suivants :

Numéro de l'éprouvette	1	2	3	4	5	6	7	8	9	10	11	12
Charge de rupture (en newtons)	2,4	2,4	2,1	2,4	2,3	2,3	1,8	2,3	2,5	2,1	1,9	2,1

On note X la variable aléatoire qui, à chaque éprouvette prélevée au hasard sur la partie extérieure de l'enroulement, associe la charge de rupture en newtons de cette éprouvette.

Déduire, du tableau ci-dessus, une estimation ponctuelle de l'espérance mathématique μ et de l'écart type σ de la variable aléatoire X .

2. a. Une autre série de 35 mesures dynamométriques d'éprouvettes prélevées au hasard sur le fond de l'enroulement et exprimées en newtons a donné les résultats suivants regroupés par classes de même amplitude :

Classe	[1,6 ; 1,7]	[1,7 ; 1,8]	[1,8 ; 1,9]	[1,9 ; 2,0]
Effectif	2	3	5	9

Classe	[2,0 ; 2,1]	[2,1 ; 2,2]	[2,2 ; 2,3]	[2,3 ; 2,4]
Effectif	8	4	3	1

Calculer la moyenne $\bar{y}$ de l'échantillon des 35 éprouvettes.

b. On note Y la variable aléatoire qui, à chaque éprouvette prélevée au hasard sur le fond de l'enroulement, associe la charge de rupture, exprimée en newtons, de cette éprouvette.

On note respectivement μ_1 et σ_1 la moyenne et l'écart type de la variable aléatoire Y .

On note $\bar{Y}$ la variable aléatoire qui, à tout échantillon de taille 35 prélevé au hasard dans le fond de l'enroulement (tirage assimilé à un tirage avec remise), associe la moyenne des 35 éprouvettes prélevées.

On admet que la variable aléatoire $\bar{Y}$ suit la loi normale

$$\mathcal{N}\left(\mu_1 ; \frac{\sigma_1}{\sqrt{35}}\right). \text{ On suppose } \sigma_1 \text{ connu : } \sigma_1 = 0,17.$$

Déterminer un intervalle de confiance au niveau 99 % de la moyenne μ_1 de la charge de rupture d'une éprouvette prélevée au fond de l'enroulement.

11 ** → CORRIGÉS, p. 247 Un opticien vend beaucoup d'appareils photographiques.

L'opticien s'intéresse aux appareils autofocus avec zoom. Il veut estimer par un intervalle de confiance le pourcentage p d'acheteurs d'appareils autofocus avec zoom dans sa clientèle.

1. Dans un échantillon de 100 clients, 60 achètent un tel appareil.

a. Donner l'estimation ponctuelle de p fournie par cet échantillon.

b. Donner une estimation de p par un intervalle de confiance avec le coefficient de confiance 95 %.

2. Déterminer la taille n , n étant supérieur à 30, d'un échantillon de clients pour qu'un intervalle de confiance de p , centré sur l'estimation ponctuelle trouvée précédemment, soit $[0,557 ; 0,643]$ avec le coefficient de confiance 90 %.

12 ** Une machine perce un trou dans une patte de fixation de bouclier avant. La variable aléatoire qui, à chaque patte de fixation, associe le diamètre du trou mesuré en millimètres suit la loi normale de moyenne $\mu = 16,56$ et d'écart type $\sigma = 0,19$.

On prélève dans la production un échantillon de taille n . Calculer n pour que la moyenne des diamètres sur les pièces prélevées appartienne à l'intervalle $[16,4 ; 16,72]$ avec la probabilité 0,95.

13 ** → CORRIGÉS, p. 247 Un magicien prétend qu'il peut souvent deviner à distance la couleur d'une carte tirée au hasard d'un jeu de cartes bien battu et comportant des cartes de deux couleurs différentes en nombre égal. On appelle p la probabilité que le magicien donne une réponse juste (succès) lors d'un tirage.

Exercices et problèmes

Si le magicien est un imposteur, on a $p = \frac{1}{2}$ sinon $p > \frac{1}{2}$.

On appelle F la variable aléatoire qui, à tout échantillon de taille 100, associe la fréquence des succès obtenus par le magicien au cours des n tirages d'une carte. On construit un test unilatéral permettant de détecter, au risque de 5 %, si le magicien est un imposteur.

On choisit comme hypothèse nulle $H_0: p = \frac{1}{2}$, et comme

hypothèse alternative $H_1: p > \frac{1}{2}$.

1. Calculer, sous l'hypothèse H_0 , le réel positif h tel que

$$P\left(F \leq \frac{1}{2} + h\right) = 0,95.$$

2. Énoncer la règle de décision du test.

3. Sur un échantillon de taille 100, le magicien a obtenu 64 succès. Peut-on considérer, au risque de 5 %, que le magicien est un imposteur ?

14 ** Une machine fabrique des barres en grande série. On veut vérifier le bon réglage de la machine.

On appelle L la variable aléatoire qui prend pour valeur la longueur d'une barre. On admet que L suit une loi normale de moyenne μ et d'écart type 1.

Dans le cas où la machine est bien réglée, la moyenne μ est égale à 1 000.

On appelle $\bar{L}$ la variable aléatoire qui prend pour valeur la moyenne des longueurs des 100 barres d'un échantillon aléatoire.

On construit un test d'hypothèse bilatéral permettant de vérifier le bon réglage de la machine au seuil de 2 %.

1. Donner l'hypothèse nulle H_0 et l'hypothèse alternative H_1 .

2. Sous l'hypothèse H_0 , quelle est la loi de $\bar{L}$?

3. Déterminer la région critique et énoncer la règle de décision relative à ce test.

15 ** Avant d'engager une campagne publicitaire, la direction de l'hypermarché demande de construire un test unilatéral qui, au vu des chiffres d'affaires journaliers des trente jours ouvrables suivant cette campagne, permettra de décider si, au seuil de signification 5 %, la moyenne des chiffres d'affaires journaliers a augmenté, c'est-à-dire dépassé 1,5 million d'euros, à la suite de cette campagne publicitaire.

1. On note μ la moyenne *inconnue* de la nouvelle population des chiffres d'affaires journaliers obtenus après la campagne publicitaire et on suppose que l'écart type de cette population est 0,3 million d'euros.

Soit Z la variable aléatoire qui, à tout échantillon aléatoire, non exhaustif, de trente chiffres d'affaires journaliers de cette nouvelle population, associe la moyenne de ceux-ci.

a. Choisir une hypothèse nulle H_0 et une hypothèse alternative H_1 pour ce test *unilatéral*.

b. Déterminer le nombre réel h tel que, sous l'hypothèse H_0 , on ait : $P(Z \leq h) = 0,95$.

c. Énoncer la règle de décision de ce test.

2. Les chiffres d'affaires journaliers pendant les trente jours ouvrables suivant la campagne publicitaire sont donnés par le tableau suivant :

Chiffre d'affaires (en millions d'euros)	1,2	1,3	1,4	1,5	1,6	1,7	1,8	1,9	2	2,1	2,2	2,3
Nombre de jours	1	2	2	8	8	2	2	1	2	1	0	1

a. Calculer la moyenne des chiffres d'affaires journaliers pendant ces trente jours.

b. En appliquant la règle de décision du test à cet échantillon de trente chiffres d'affaires journaliers que l'on assimile à un échantillon aléatoire non exhaustif, peut-on conclure, au seuil de signification 5 % qu'à la suite de la campagne publicitaire la moyenne des chiffres d'affaires journaliers a dépassé 1,5 million d'euros ?

Pour se préparer au BTS

16 *** Deux laboratoires A et B fabriquent des tubes à essai et les conditionnent dans des paquets.

Tous les paquets contiennent le même nombre de tubes.

1. On note X_1 la variable aléatoire qui prend pour valeur le nombre de tubes défectueux par paquet provenant de l'entreprise A. Sur un échantillon aléatoire de 49 paquets provenant du laboratoire A les nombres des tubes défectueux par paquet sont les suivants :

7, 5, 5, 4, 4, 4, 9, 7, 9, 2, 7, 8, 7, 8, 4, 4, 9, 10, 5, 10, 6, 4, 5, 6, 1, 2, 5, 7, 8, 0, 6, 0, 1, 5, 2, 0, 5, 2, 3, 3, 4, 1, 3, 10, 1, 0, 10, 2, 7.

Calculer une valeur approchée à 10^{-2} près de la moyenne m_1 et de l'écart type s_1 de cet échantillon. On admet dans la suite de cet exercice qu'une estimation ponctuelle $\hat{\mu}_1$ de la moyenne μ_1 de la variable aléatoire X_1 est 4,84 et qu'une estimation ponctuelle $\hat{\sigma}_1$ de l'écart type σ_1 de X_1 est 2,99.

2. On note X_2 la variable aléatoire qui prend pour valeur le nombre de tubes défectueux par paquet provenant de l'entreprise B. Sur un échantillon aléatoire de 64 paquets provenant de l'entreprise B, on a obtenu une moyenne m_2 de 3,88 tubes défectueux et un écart type s_2 de 1,45. En déduire une estimation ponctuelle $\widehat{\mu}_2$ de la moyenne μ_2 de la variable aléatoire X_2 et une estimation ponctuelle $\widehat{\sigma}_2$ de l'écart type σ_2 de X_2 .

3. On se propose de construire un test d'hypothèse pour comparer les qualités de production des laboratoires A et B. On note $\overline{X}_1$ la variable aléatoire prenant pour valeur le nombre moyen de tubes défectueux par paquet dans des échantillons aléatoires de 49 paquets de la production du laboratoire A.

On note $\overline{X}_2$ la variable aléatoire prenant pour valeur le nombre moyen de tubes défectueux par paquet dans des échantillons aléatoires de 64 paquets de la production du laboratoire B.

a. Le nombre d'observations étant important, on admet que les lois de probabilité de $\overline{X}_1$ et $\overline{X}_2$ peuvent être approchées par des lois normales.

Exprimer la moyenne et l'écart type de chacune de ces variables aléatoires en fonction de ceux de X_1 et de X_2 .

Dans toute la suite, on considère donc que $\overline{X}_1$ et $\overline{X}_2$ sont deux variables aléatoires indépendantes suivant une loi normale.

b. On note D la variable aléatoire telle que :

$$D = \overline{X}_1 - \overline{X}_2.$$

Quelle est la loi de probabilité de D ? Déterminer la moyenne et l'écart type de D . Justifier.

4. Dans cette question, on admet que D suit la loi normale $\mathcal{N}(\mu_1 - \mu_2; 0,46)$.

On pose pour hypothèse nulle $H_0 : \mu_1 = \mu_2$ et pour hypothèse alternative $H_1 : \mu_1 \neq \mu_2$.

a. Calculer, sous l'hypothèse H_0 , les nombres h et k tels que $P(-h < D < h) = 0,99$ et $P(-k < D < k) = 0,95$.

b. Énoncer la règle de décision relative à ce test lorsqu'on choisit un seuil de signification de 1 %, puis de 5 %.

5. Peut-on conclure après examen des échantillons donnés dans les questions 1 et 2 que la différence des moyennes observées est significative au seuil de risque de 1 % ? Au seuil de risque de 5 % ?

17 *** BTS Groupement B 2011

Les trois parties de cet exercice peuvent être traitées de façon indépendante.

Une entreprise fabrique des barres de combustible pour des centrales électriques.

Des pastilles de combustible sont introduites dans des gaines qui servent à réaliser ces barres.

Les résultats approchés sont à arrondir à 10^{-3} près.

A. LOI NORMALE

Une gaine est considérée comme conforme pour le diamètre lorsque le diamètre intérieur, exprimé en millimètres, appartient à l'intervalle $[8,18; 8,48]$.

On note X la variable aléatoire qui, à chaque gaine prélevée au hasard dans la production d'une journée, associe son diamètre intérieur.

On admet que X suit la loi normale de moyenne 8,33 et d'écart type 0,09.

1. Calculer la probabilité qu'une gaine ainsi prélevée soit conforme pour son diamètre intérieur.

2. Calculer le nombre réel h positif tel que : $P(8,33 - h \leq X \leq 8,33 + h) = 0,95$. Interpréter le résultat à l'aide d'une phrase.

B. LOI BINOMIALE

On considère un stock important de gaines. On note E l'événement : « une gaine prélevée au hasard dans le stock n'est pas conforme pour le diamètre intérieur ».

On suppose que $P(E) = 0,096$.

On prélève au hasard 50 gaines dans le stock pour vérification du diamètre intérieur.

Le stock est suffisamment important pour que l'on puisse assimiler ce prélèvement à un tirage avec remise de 50 gaines.

On considère la variable aléatoire Y qui, à tout prélèvement de 50 gaines ainsi défini, associe le nombre de gaines non conformes pour le diamètre intérieur de ce prélèvement.

1. Justifier que la variable aléatoire Y suit une loi binomiale dont on précisera les paramètres.

2. Calculer la probabilité que, dans un tel prélèvement, cinq gaines ne soient pas conformes pour le diamètre intérieur.

3. Calculer la probabilité que, dans un tel prélèvement, au plus deux gaines ne soient pas conformes pour le diamètre intérieur.

C. TEST D'HYPOTHÈSE

On se propose de construire un test d'hypothèse pour contrôler la moyenne μ inconnue des diamètres, exprimés en millimètres, d'un lot important de pastilles de combustible destinées à remplir les gaines.

On note D la variable aléatoire qui, à chaque pastille prélevée au hasard dans le lot, associe son diamètre.

On admet que la variable aléatoire D suit la loi normale de moyenne inconnue μ et d'écart type 0,2.

On désigne par $\overline{D}$ la variable aléatoire qui, à chaque échantillon aléatoire de 300 pastilles prélevées dans le lot, associe la moyenne des diamètres de ces pastilles (le lot est assez important pour que l'on puisse assimiler ces prélèvements à des tirages avec remise).

Exercices et problèmes

L'hypothèse nulle est $H_0 : \mu = 8,13$. Dans ce cas, la livraison est dite conforme pour le diamètre.

L'hypothèse alternative est $H_1 : \mu \neq 8,13$.

Le seuil de signification du test est fixé à 5 %.

1. Sous l'hypothèse nulle H_0 , on admet que la variable aléatoire D suit la loi normale de moyenne 8,13 et d'écart type 0,012.

On admet également que $P(8,106 \leq D \leq 8,154) = 0,95$. Ce résultat n'a pas à être démontré.

Énoncer la règle de décision permettant d'utiliser ce test.

2. On prélève un échantillon aléatoire de 300 pastilles dans la livraison reçue et on observe que, pour cet échantillon, la moyenne des diamètres des pastilles est $\bar{d} = 8,16$. Peut-on, au seuil de 5 %, conclure que la livraison est conforme pour le diamètre ?

18 *** BTS Groupement C 2008

Les résultats seront arrondis au centième.

PARTIE A

Dans une usine U, une machine produit des barres de métal.

Dans cette partie, on étudie la longueur de ces barres.

On définit la variable aléatoire X qui à chaque barre associe sa longueur exprimée en centimètres et on admet que la variable aléatoire X suit une loi normale de moyenne $m = 92,50$ et d'écart type σ .

Une barre de la production est mise au rebut si sa longueur est inférieure à 92,20 cm ou supérieure à 92,80 cm.

1. On suppose que $\sigma = 0,20$.

a. Calculer la probabilité qu'une barre extraite au hasard dans la production de la machine soit mise au rebut.

b. Déterminer le réel a tel que la probabilité que la variable aléatoire X prenne des valeurs comprises entre $92,5 - a$ et $92,5 + a$ soit égale à 0,95.

2. Quelle valeur faut-il donner à l'écart type σ pour que la probabilité de mise au rebut d'une barre soit égale à 0,08 ? Dans la suite de l'exercice, on suppose que l'écart type est $\sigma = 0,17$.

PARTIE B

Dans la production de la machine, 8 % des barres sont mises au rebut. On prélève un lot de 30 barres extraites

au hasard dans la production de la machine. Le nombre de barres produites est suffisamment important pour que l'on assimile ce prélèvement à un tirage avec remise de 30 barres.

On appelle N la variable aléatoire qui à chaque lot de 30 barres associe le nombre de barres qui sont mises au rebut dans ce lot.

1. Déterminer la loi de probabilité suivie par la variable aléatoire N et donner ses paramètres. Justifier.

2. Calculer la probabilité qu'aucune barre de ce lot ne soit mise au rebut.

3. Calculer la probabilité que, dans un tel lot, au moins 90 % des barres ne soient pas mises au rebut.

PARTIE C

La machine se dérégulant dans le temps, on veut tester la moyenne m des longueurs des barres qu'elle produit. On se demande si on peut accepter, au seuil de risque de 5 %, l'hypothèse selon laquelle la moyenne m des longueurs des barres est encore de 92,50 cm.

Pour cela, on construit un test d'hypothèse bilatéral.

On suppose que la variable aléatoire X , qui à tout échantillon de 30 barres de métal prélevées au hasard associe la moyenne des longueurs en centimètres des barres de l'échantillon, suit une loi normale de moyenne m et d'écart type 0,03.

On choisit l'hypothèse nulle $H_0 : m = 92,50$.

1. Donner l'hypothèse alternative H_1 .

2. Sous l'hypothèse H_0 , calculer le réel h tel que : $P(92,5 - h < X < 92,5 + h) = 0,95$.

3. Énoncer la règle de décision du test.

4. On prélève un échantillon de 30 barres extraites au hasard dans la production de la machine, on obtient les résultats suivants :

Longueur (cm)	92,1	92,2	92,3	92,4	92,5	92,6	92,7	92,8	92,9
Nombre de barres	3	2	6	5	5	3	2	2	2

Au vu des résultats de cet échantillon, peut-on admettre au seuil de risque de 5 %, l'hypothèse selon laquelle la moyenne m des longueurs des barres est encore de 92,50 cm ?